

MaiAgent Technical Documentation

Table of Contents

1. 生成 AI クイックスタート

- 1.1 大規模言語モデル（LLM）
- 1.2 RAG ナレッジベース検索システム
- 1.3 Embedding モデル
- 1.4 Reranker モデル
- 1.5 Parser 解析ツール
- 1.6 画像認識サポート

2. 技術原理

- 2.1 システムプロンプト
- 2.2 回答の評価とモニタリング結果
- 2.3 Text to SQL
- 2.4 Function Calling
- 2.5 Skill スキルモジュール
- 2.6 Canvas
- 2.7 AI 安全保護機構
- 2.8 OAuth 2.0 連携と Token 自動更新機構
- 2.9 ICAP コンテンツ検証連携

3. MaiAgent Work | 従業員の生産性向上のための連携

- 3.1 MaiGPT をシステムに追加します
- 3.2 MaiGPT 連携：適切な Agent の選択と機能の補完

4. MaiAgent Serve | カスタマーサービス連携

- 4.1 ソフトウェアベンダー向け連携ガイド：顧客向けに AI Agent を組み込みます
- 4.2 Web Chat の埋め込みと SDK
- 4.3 MaiGPT モードの埋め込み
- 4.4 ページ Context の注入
- 4.5 LINE LIFF：LINE LIFF とは

- 4.6 LINE LIFF：連携方法
- 4.7 連絡先 (Contact) の紹介と連携
- 4.8 連絡先の ID 同期と Token 更新
- 4.9 ロール (Role) と連絡先 (Contact) の違い
- 4.10 外部カスタマーサービスシステムとの連携（オペレーターへの引き継ぎを含む）
- 4.11 会話の引き継ぎと継続 API
- 4.12 Webhook

5. MaiAgent Build | API 連携ガイド

- 5.1 クイックスタート
- 5.2 API 共通規約
- 5.3 会話とメッセージの作成
- 5.4 会話とメッセージの応答（ストリーミング/同期）
- 5.5 Presigned ファイルアップロード方式
- 5.6 ナレッジベースの使用—アップロード、検索、管理
- 5.7 API ツールエンジニアリングガイド
- 5.8 n8n 連携
- 5.9 Google Sheet 連携
- 5.10 エンドポイント動作の補足
- 5.11 会話添付ファイル管理 API
- 5.12 会話の出力一覧 API
- 5.13 会話の閲覧権限とリアルタイムイベント
- 5.14 メンバーのメモリ管理 API
- 5.15 サイトのブランド設定 API
- 5.16 Credits 項目の表示順序
- 5.17 Agent の回答モードと構造化出力フィールド
- 5.18 会話記録の使用量と Credits フィールド
- 5.19 組み込みワークフロー応答モードの廃止

6. MaiAgent Build | MCP と外部サービス

- 6.1 MCP（Model Context Protocol）
- 6.2 MaiAgent MCP：外部 AI ツールによるプラットフォーム操作
- 6.3 セルフホスト MCP Server の接続仕様
- 6.4 Remote MCP サービス概要
- 6.5 Composio 連携
- 6.6 Zapier 連携

7. MaiAgent Build | AI Gateway

7.1 AI Gateway：OpenAI 互換 API 連携

7.2 AI Gateway のセキュリティ

8. ID と権限

8.1 メンバーのプロビジョニング：SCIM／招待／SSO

8.2 リアルタイム同期：ユーザーイベントからの呼び出し

8.3 メンバー一覧の同期ツール：CSV／JSON／データベース

8.4 SSO と ID 連携の概要

8.5 SAML SSO シングルサインオン連携

8.6 OAuth 認可サーバーとしての MaiAgent

8.7 ナレッジ管理権限（Query Metadata / クエリメタデータ）概要

8.8 構築の開始—JSON 形式の使用

9. プラットフォームの構築とデプロイ

9.1 概要

9.2 プラットフォーム環境（SaaS/プライベートクラウド/オンプレミス）

9.3 デプロイアーキテクチャ

9.4 デプロイ形態と機能の比較

9.5 システム要件

9.6 バージョンとアップグレード

9.7 オンプレミスモデルサービスの接続

9.8 運用の要点：オフラインインストール、TLS、バックアップ、モニタリング、受け入れ検証

9.9 独自のベクトルデータベースの使用

9.10 クラウドモデル推論 API サービス

9.11 GPU 計算リソースのハードウェア計画

9.12 ファイルライブラリでの Office オンライン編集（ONLYOFFICE Docs 連携）

生成 AI クイックスタート

大規模言語モデル（LLM）

選択のポイント

大規模言語モデルを選択する際は、以下の重要な要素を考慮してください。

環境（Environment）：利用環境がインターネットに接続できるかどうかに応じて、クラウドまたはオンプレミスモデルを選択します。

品質（Quality）：モデルの回答生成能力と、指示に従う能力です。

速度（Speed）：適切な応答速度を確保するため、テキスト生成速度と遅延の要件を考慮します。

価格（Pricing）：モデルごとに Credits の料金が異なります。利用要件と予算に応じて選択してください。料金体系は [Credits の課金制度](#) をご覧ください。

その他：マルチモーダルや Function calling に対応しているかどうかです。

モデルの品質、速度、価格の比較については、[Artificial Analysis](#) など、継続的に更新される第三者の評価を参考にしてください。

MaiAgent で対応する大規模言語モデル

MaiAgent で提供するモデルは、プロバイダーによるリリースや提供終了に応じて継続的に更新されます。このページでは、具体的なモデル名ではなく、プロバイダーとモデルファミリーのみを掲載しています。組織で実際に選択できるモデルは、管理画面の「[モデル呼び出し権限](#)」ページをご確認ください。このページには MaiAgent が組織向けに利用可能にしたモデルが表示され、組織オーナーはその範囲内でモデルを有効または無効にできます。

クローズドソースモデル

モデルプロバイダー	モデルファミリー	推論サービス
OpenAI	GPT、o シリーズ	OpenAI、Azure、AWS Bedrock
Anthropic	Claude	AWS Bedrock、Google Vertex AI
Google	Gemini	Google Vertex AI
xAI	Grok	OpenAI 互換 API
Alibaba	Qwen（Max、Plus）	OpenAI 互換 API
Amazon	Nova	AWS Bedrock

オープンソースモデル

オープンウェイト（open-weight）モデルは、MaiAgent SaaS 上でクラウド推論サービスを通じて利用できるほか、プライベートクラウドやオンプレミスで自前の GPU にデプロイすることもできます。必要なハードウェアは [GPU](#) の章をご覧ください。

モデルプロバイダー	モデルファミリー	SaaS 上の推論サービス
OpenAI	GPT-OSS	OpenAI 互換 API
Google	Gemma	OpenAI 互換 API
Alibaba	Qwen、Qwen-VL	OpenAI 互換 API
DeepSeek	DeepSeek	AWS Bedrock、Azure
Mistral AI	Mistral	OpenAI 互換 API
Moonshot AI	Kimi	OpenAI 互換 API
IBM	Granite	OpenAI 互換 API

オンプレミスで自前の環境にデプロイできるモデルは、MaiAgent デプロイパッケージのモデルカタログに準拠します。現在は GPT-OSS、Gemma、Qwen、Qwen-VL などのファミリーが含まれています。デプロイ計画については MaiAgent の担当窓口にご相談ください。

プロバイダーの種類によって、対応する LLM、Embedding、Reranker の範囲が異なります。詳しくは [モデル API 推論サービス](#) をご覧ください。

モデルには必ず Fine-tune が必要ですか？

AI 技術の急速な発展により、言語モデルは優れた言語理解・生成能力を備え、多くの分野で広く活用されています。たとえば、事前学習済みの言語モデルは、日常会話、文章生成、簡単な質問応答に容易に対応できます。

一方、医療、法律、テクニカルサポートなど、専門分野のより難しいタスクでは、事前学習済みモデルだけに頼ると最適な性能を得られない場合があります。そのため、特定分野の追加学習によってモデルの専門知識を向上させる **Fine-tuning** を選択する開発者もいます。

ただし、Fine-tuning だけが解決策ではありません。同じ目的を達成できる有効な方法として、**Prompt Engineering** と **RAG (Retrieval-Augmented Generation)** もあります。

1. Prompt Engineering：正確なプロンプトでモデルの性能を最適化します

Prompt Engineering は、正確なプロンプトを設計し、モデルが望ましい結果を生成するように導く方法です。タスクの要件に応じて詳細な指示を設計し、回答の範囲を絞り、文脈と必要な出力形式をモデルが理解できるようにすることが中心となります。

たとえば、ユーザーの要望に基づいて適切な製品を推薦する言語モデルがあるとします。「高性能なスマートフォンを買いたい」と伝えるだけでは、十分に正確な回答が得られない場合があります。「高性能」には処理速度、カメラ性能、バッテリーの持続時間など、さまざまな解釈があるためです。

推薦の精度を高めるには、**Prompt Engineering** によって、より具体的な質問や追加の文脈を用意し、モデルがユーザーの要望をよりよく理解できるようにします。たとえば、次のプロンプトに変更できます。

"**バッテリーが長持ちし、効率の良いプロセッサ**を搭載したスマートフォンが必要です。価格は **500 米ドルから 800 米ドル**の範囲で、条件を満たす機種をいくつか推薦してください。"

2. RAG：外部知識を組み合わせて生成能力を向上させます

RAG は、外部知識の検索と生成プロセスを組み合わせることで、モデルの性能を向上させます。

従来の生成タスクでは、モデルは事前学習で得た知識のみに依存します。一方 RAG は、検索システムで外部データをリアルタイムに取得し、それを生成モデルと組み合わせることで、より正確な回答やテキストを生成します。

たとえば医療分野で、ある希少疾患についてモデルが質問された場合、RAG はまず専門の医療データベースから関連情報を検索し、その情報に基づいてより正確な回答を生成できます。この方法では、モデルが学習時に見たことのない情報でも、既存の知識を検索することで質の高い回答を提供できます。特に、知識のリアルタイムな更新が必要な場面に適しており、モデルが扱える知識の範囲を大きく広がられます。

RAG の詳しい紹介は、次の章の「[RAG ナレッジベース検索システムの説明](#)」をご覧ください。

Fine-tuning、Prompt Engineering、RAG には、それぞれ長所と適用範囲があります。Fine-tuning だけに頼らず、利用シーンと要件に応じて最適な戦略を選択できます。

Prompt Engineering は、正確なプロンプトを設計してモデルを質の高い結果へ導く、低コストで柔軟な方法です。

RAG は、外部知識と生成能力を組み合わせ、知識を動的に取得する必要がある場合に、より正確な回答を提供する方法です。

Fine-tuning は、特定分野でのモデルの性能を大幅に向上させられますが、大量の専門データと追加のリソースが必要です。**Prompt Engineering** と **RAG** の両方で目的を達成できない場合の最終手段として検討できます。

MaiAgent プラットフォームはモデルのファインチューニング機能を提供していません：管理画面にはモデルの学習やファインチューニングを行うインターフェースがなく、プラットフォームがお客様のデータをモデルの学習に使用することはありません。上記の Fine-tuning は、モデルプロバイダーや自前のモデルを構築するチームが、プラットフォームの外部で行うものです。ファインチューニング済みのモデルは、次の方法で接続できます。クラウドプロバイダーがホストするモデルは、お客様自身の API キーで接続します（[AI Gateway：OpenAI 互換 API 接続](#)をご覧ください）。自前で学習したオープンウェイトモデルは、プライベートクラウドやオンプレミスで OpenAI 互換のモデルサービスとしてデプロイしてから接続します。[オンプレミスモデルサービスの接続](#)をご覧ください。Agent に専門知識を持たせるには、まず [ロール指示](#)と [RAG ナレッジベース](#)を利用してください。

RAG ナレッジベース検索システム

RAG（Retrieval-Augmented Generation、検索拡張生成）では、大規模言語モデルが回答する前に、ナレッジベースから質問に関連する段落を取得し、その内容に基づいて回答します。これにより、モデルは学習データだけに頼らず、組織独自の文書を参照できます。

RAG の処理フロー

RAG は、資料の持ち込みが可能な試験に例えられます。モデルがすべての資料を暗記する必要はなく、回答するたびにナレッジベースを調べ、質問に最も関連する段落を根拠として使います。そのため、ナレッジベースには Agent のタスクに関連する資料だけを入れることをおすすめします。無関係な内容もコンテキストとして検索される可能性があり、かえって回答の精度を下げる場合があります。

本ページでは、MaiAgent の実際の処理フローと調整できるパラメーターを説明します。管理画面の操作手順は、ユーザーマニュアルの [ナレッジベースの概要](#) をご覧ください。

データがナレッジベースに取り込まれる流れ

ナレッジベースにアップロードされたファイルは、順に以下の処理を受けます。

解析：パーサーがファイルをテキストに変換します（必要に応じてテーブルや画像も処理します）。[Parser 解析ツール](#) をご覧ください。

チャンク分割：テキストを段落（チャンク）に分割します。その後の検索と引用は、この段落を単位として行います。

ベクトル化：ナレッジベースで選択した Embedding モデルが各段落をベクトルに変換します。[Embedding モデル](#) をご覧ください。

ベクトルデータベースへの書き込み：段落のテキストとベクトルを一緒にベクトルデータベースへ書き込みます。デフォルトではプラットフォーム内蔵のデータベースを使用しますが、独自のデータベースにも接続できます。[独自のベクトルデータベースの利用](#) をご覧ください。

ファイルのステータスが **done** になってから、内容が検索対象になります。

1 回の検索の流れ

1. 検索範囲の決定

検索前に、プラットフォームが今回検索できるナレッジベース、ファイル、ラベルを決定し、その条件をベクトルデータベースのクエリに直接適用します。範囲外の段落は検索結果に含まれず、モデルにも渡されません。

範囲は、メッセージ → 会話 → 連絡先のクエリメタデータ（Query Metadata）の順に取得します。いずれも設定されていない場合は Agent のデフォルトのラベルフィルターを適用し、それらなければナレッジベース全体を検索します。設定方法は [Query Metadata の概要](#) と、ユーザーマニュアルの [ナレッジベースのラベルフィルタリング](#) をご覧ください。

「誰がどの文書を閲覧できるか」を制限するには、クエリメタデータまたはラベルフィルターを使用し、システムプロンプトだけに頼らないでください。システムプロンプトは検索後にモデルに渡すテキストであり、すでに検索された段落を遮断することはできません。

2. ハイブリッド検索

デフォルトでは、**ハイブリッド検索**で2種類のクエリを同時に実行します。

ベクトル検索：質問のベクトルを使って意味の近い段落を探します。表現が異なっても見つけられます。

キーワード検索（BM25）：語句を照合します。製品の型番、固有名詞、コードの検索に適しています。

ナレッジベースで **Reciprocal Rank Fusion を有効化**（RRF）をオンにすると、2種類の結果を RRF によって順位に基づいて統合します。Elasticsearch で RRF を使用するには、Enterprise、Platinum、Trial のいずれかのライセンスが必要です。独自の Elasticsearch に該当ライセンスがない場合、管理画面でこのオプションが自動的に無効になります。プラットフォームでハイブリッド検索が無効になっている場合は、ベクトル検索のみを使用します。

Agent との会話では、常にプラットフォームの設定に従って検索し、別のモードは選べません。一方、管理画面の **検索テスト** と **ナレッジベース検索 API** では、ベクトルのみ（**セマンティック検索**、`semantic`）またはキーワードのみ（**キーワード検索**、`keyword`、Elasticsearch のみ）を指定し、それぞれが何を取得するか比較できます。

3. Reranker による並べ替え

ナレッジベースで **検索結果の並べ替えを有効化 (Reranking)** をオンにすると、最初の段階で多めに候補段落を取得します（**取得チャンク数** × プラットフォーム設定の倍率。デフォルトは7倍です）。その後、Reranker モデルが質問と各段落を比較して再評価し、スコアが高い順に **取得チャンク数** 件だけを残します。**Reranker モデル** をご覧ください。

組織の Credits がプラットフォームのしきい値を下回ると、その会話では Reranker をスキップし、最初の段階の結果をそのまま使用します。

4. 類似度しきい値

類似度しきい値（0-1） は、Reranker のスコアがしきい値を下回る段落を除外します。デフォルトは0で、フィルタリングしません。このしきい値は Reranker のスコアに適用されるため、**Reranker が有効な場合のみ機能します**。高く設定しすぎると段落が1件も残らず、モデルが参照できる資料がなくなる場合があります。

5. 複数のナレッジベースの統合

Agent に複数のナレッジベースが接続されている場合、各ナレッジベースの結果を統合し、Agent の **最大取得ブロック数** に従って、最終的にモデルへ渡す段落数を決定します。今回検索したナレッジベースのうち 1 つでも Reranker が有効であれば、統合後の結果をもう一度並べ替えます。

6. モデルへの送信と引用の表示

選択した段落を、Agent のシステムプロンプトと一緒に大規模言語モデルへ送信します。ファイルのメタデータフィールドで **検索時に使用** をオンにしている場合、その値もモデルへ渡され、回答の判断材料になります。回答内の引用から、元の段落とファイルにアクセスできます。

Agentic RAG : Agent モードでの検索

上記のフローは「1 回の検索、1 回の生成」です。各メッセージで必ず検索してから回答し、モデルは検索するかどうかが何を検索するかを決定しません。Agentic RAG では、検索の判断をモデルに委ねます。回答中に検索を複数回呼び出し、前回の結果に応じてクエリを調整したり、キーワードを変更したり、別のファイルを読んだりしたうえで、回答をまとめることができます。

MaiAgent では、この 2 つの方式は Agent の回答モードに対応します。

回答モード	検索方法
RAG Q&A (API の <code>replyMode: normal</code>)	1 回の検索：各メッセージで本ページのフローに従って 1 回検索し、段落を直接モデルへ渡します
Agent モード (<code>replyMode: agent</code>)	Agentic RAG：ナレッジベースをツールとしてモデルに提供します。同じターン内で段落を複数回検索し、ファイル名やメタデータでファイルを絞り込み、キーワードでファイル内容を検索し、ファイル全体を読むことができます。各呼び出しは本ページの検索フローに従います (Query Metadata による範囲制限を含みます)

Agent モードの検索回数は Agent の実行上限によって制限されます (**Function Calling : 実行上限** をご覧ください)。遅延と使用量も 1 回の検索より増えます。回答が 1 つの段落にある Q&A 用途では RAG Q&A で十分です。複数の文書を比較したり、ファイルを探してから詳しく読んだりする用途には Agent モードを使用してください。

会話モードと Agent モードでのナレッジベース検索

前節を踏まえて、2 つのモードの違いを項目ごとに比較します。

	RAG Q&A（会話モード、 <code>replyMode: normal</code> ）	Agent モード（ <code>replyMode: agent</code> ）
検索のタイミング	各メッセージに回答する前に、モデルの判断を介さず 必ず 1回検索します	検索は ツール です。モデルが質問に応じて、呼び出すかどうか、回数、クエリ文字列を決定します
取得件数	各ナレッジベースでそれぞれの 取得チャンク数 を取得し、統合後に Agent の 最大取得ブロック数 で切り詰めます	<code>retrieve_text_nodes</code> ツールの <code>top_k</code> はモデルが指定します（デフォルトは3）。そのため、通常は取得チャンク数より少なくなります。Agent で 完全な検索範囲の使用を強制 をオンにした場合は、常に 最大取得ブロック数 を使用します
利用できるツール	ありません。今回取得した段落だけを使用します	<code>retrieve_text_nodes</code> （セマンティック／ハイブリッド検索）、 <code>query_files</code> （ファイルとメタデータの一覧）、 <code>grep_files</code> （ファイル内容の文字列照合）、 <code>read_file</code> （ファイル全体の読み取り）、 <code>get_surrounding_context</code> （段落の前後のコンテキスト取得）、 <code>image_search</code> （マルチモーダルのナレッジベースでの画像検索。ツール設定で無効化できます）
クエリメタデータ、ラベルフィルター、Reranker、類似度しきい値	両モードに同じルールで適用されます	
会話中にアップロードした添付ファイル	アップロード時に直ちに解析とインデックス作成を行い、回答時にナレッジベースと一緒に検索します。取得件数には Agent の最大取得ブロック数を使います	アップロード時には解析しません。Agent が質問に応じて添付ファイルツール（ <code>parse_attachment_content</code> 、 <code>read_attachment_full_text</code> 、 <code>ingest_attachment</code> ）で読み取りやインデックス作成を行います。 <u>メッセージの添付ファイルの処理</u> をご覧ください
検索結果が不十分な場合	ナレッジベースのパラメータと Agent の最大取得ブロック数を調整します	まずモデルが検索ツールを呼び出したか確認します（ <u>会話詳細と実行タイムライン</u> でツール呼び出しを確認できます）。その後、パラメータを調整するか、システムプロンプトで先にナレッジベースを検索するよう指示します

Agent で **ツール検索機能を有効化**（動的ツール検索）をオンにすると、ナレッジベースのツールも「検索してから読み込む」対象になります。Text to SQL や API ツールと同様に、先に `tool_searching_tool` を呼び出す必要があります。モデルが検索をスキップし、「ナレッジベース検索ツールがない」と回答して他のツールだけを使う場合があります。その際は、システムプロンプトに「回答前に `retrieve_text_nodes` でナレッジベースを検索してください」と明記するか、ツール検索を無効にしてすべてのツールを直接利用できるようにしてください。ナレッジベースを接続するだけでは自動検索は行われず、検索ツールを別途作成する必要也没有ありません。

調整できるパラメーター

パラメーター	設定場所	デフォルト値	説明
Embedding モデル	ナレッジベース	プラットフォーム設定によります	作成後は管理画面で変更できません。変更するには別のナレッジベースを作成するか、MaiAgent の担当者にお問い合わせください
取得チャンク数	ナレッジベース	12	各ナレッジベースから取得する段落の最大数です。最小値は1です
検索結果の並べ替えを有効化 (Reranking)	ナレッジベース	有効	有効にすると、ナレッジベースで選択した Reranker モデルを使用します
類似度しきい値 (0-1)	ナレッジベース	0	Reranker が有効な場合のみ機能します
Reciprocal Rank Fusion を有効化	ナレッジベース	プラットフォーム設定によります	ハイブリッド検索の結果を統合する方法です。OpenSearch のハイブリッド検索では有効化が必須です
最大取得ブロック数	Agent	12	会話時に最終的にモデルへ渡す段落数です。画面では5～15が推奨され、数値が高いほど遅延が増えます

特定の質問でどの段落が取得されるか確認するには、管理画面の 検索テスト を使用するか、ナレッジベース検索 API を呼び出してください。

調整方法

チャンクのサイズと重なりはパーサーが決定し、管理画面には調整項目がありません。調整できるのは以下のパラメーターです。1 回に 1 項目だけを変更し、同じ質問セットを使って検索テストで比較してください。

症状	最初に確認すること	次の調整
正しい段落が見つかるものの、順位が低いか切り捨てられます	検索テストでの順位を確認します	Reranker を有効にします。それでも不十分な場合は取得チャンク数と最大取得ブロック数を増やします（遅延と token 使用量が増えます）
無関係な段落が頻繁に含まれます	Reranker を有効にした後の段落順を確認します	類似度しきい値を上げます（1 回に 0.05～0.1 ずつ。高すぎると結果がなくなります）。またはラベルフィルターで範囲を絞ります
型番、コード、固有名詞が見つかりません	キーワード検索で見つかるか確認します	文書の表記がユーザーと一致しているか確認します。ハイブリッド検索が無効な場合は有効に戻します（Elasticsearch には RRF ライセンスが必要です）

症状	最初に確認すること	次の調整
テーブルや長い文書について、部分的な回答しか得られません	チャンクがテーブルを分断していないか確認します	別のパーサーで再解析するか、チャンク内にテーブルのヘッダーや章名を追加するか、Agent で完全な検索範囲の使用を強制する設定をオンにします
回答で添付ファイルだけが使われ、ナレッジベースが使われません（またはその逆です）	Agent モードのツール呼び出し履歴を確認します	システムプロンプトで先にナレッジベースを検索するよう明記します。会話モードでは両方を一緒に検索するため、最大取得ブロック数を増やします
Reranker を有効にしても効果がありません	組織の Credits がプラットフォームのしきい値を下回っていないか確認します（下回ると Reranker が自動的にスキップされます）	先に Credits をチャージしてから比較します

Embedding モデルは作成後に変更できず、モデルを変更するにはナレッジベースを再構築する必要があります。本番運用を開始する前に、検索テストで異なるモデルの結果を比較して決定してください。

Embedding モデル

Embedding とは？

Embedding モデルは、テキストを数値の列（ベクトル）に変換します。意味が近いテキストは近いベクトルになるため、質問とドキュメントの表現が異なっても、システムはベクトル間の距離を使って意味的に関連する段落を見つけられます。

MaiAgent の RAG 処理では、Embedding モデルが次の 2 つの処理を行います。

インデックスの作成：ナレッジベースの解析後の各段落をベクトルに変換し、ベクトルデータベースに保存します。

質問の変換：ユーザーの質問をベクトルに変換し、データベース内の段落との類似度を比較します。

RAG の処理フロー

検索処理の全体については、[RAG ナレッジベース検索システム](#)をご覧ください。

選択前に知っておくこと

作成後は管理画面で変更できません：Embedding モデルはナレッジベースの作成時に選択します。異なるモデルが生成したベクトル同士は比較できません。変更する場合は、新しいナレッジベースを作成するか、MaiAgent の担当者にお問い合わせください。

画像ファイルにはマルチモーダルモデルが必要です：画像ファイル（.png、.jpg など）をナレッジベースに追加してインデックスを作成するには、マルチモーダルに対応した Embedding モデルを使用する必要があります。対応していない場合、そのファイルの解析は失敗します。

Agent は複数のモデルを併用できます：同じ Agent に、異なる Embedding モデルを使うナレッジベースを接続できます。プラットフォームはそれぞれを検索し、結果を統合します。

MaiAgent クラウドで有効なモデル

以下は、2026 年 10 月時点の本番環境で有効なモデルの一覧です。ナレッジベースの作成時に選択できるモデルは、管理画面の表示に従ってください。

モデル（管理画面での名称）	プロバイダー	画像ファイル対応
OpenAI text-embedding-3	OpenAI（text-embedding-3-large）	いいえ

モデル（管理画面での名称）	プロバイダー	画像ファイル対応
Cohere Embed V4.0	Cohere (<code>embed-v4.0</code>)	はい
Cohere Embed Multilingual v3.0 (Bedrock)	AWS Bedrock (<code>cohere.embed-multilingual-v3</code>)	いいえ

オンプレミス展開

オンプレミスおよびプライベートクラウドでは、Embedding モデルをローカルに展開する（展開パッケージのモデルカタログには、GPU が必要な `jina-embeddings-v3` が含まれています）か、既存のモデルサービスやクラウドプロバイダーに接続できます。利用可能なモデルと接続方法については、[オンプレミスのモデルサービス接続](#)をご覧ください。各クラウドプロバイダーの Embedding 対応については、[クラウドモデル推論 API サービス](#)をご覧ください。

独自の Embedding サービスのインターフェース要件

自社構築またはサードパーティーの OpenAI 互換 Embedding サービスに接続する場合、URL に `/v1` を含め、サービスが MaiAgent の送信するパラメーターを受け付ける必要があります。対応していない場合、すべてのナレッジベースファイルの解析が失敗します。詳しい要件については、[オンプレミスのモデルサービス接続：独自の Embedding と Reranker の制限](#)をご覧ください。

Embedding モデルは、関連する内容を見つけられるかどうかに影響します。特定の質問で正しい段落が見つからないことが多い場合は、まず管理画面の[検索テスト](#)で結果を確認してください。そのうえで、[Reranker](#)や検索する段落数の調整、または別の Embedding モデルを使ったナレッジベースの再作成を検討してください。

Reranker モデル

Reranker とは？

Reranker は「並べ替え」に特化したモデルです。第1段階の検索（ベクトル検索とキーワード検索）は高速ですが、大まかな照合しかできません。Reranker は質問と各候補段落を組み合わせて関連度を個別に評価し、スコア順に並べ替えることで、質問への回答となる段落を上位に表示します。

初期検索

ベクトル検索とキーワード検索で、ナレッジベースから候補段落をすばやく取得します。

再スコアリング

Reranker が「質問＋段落」を個別に照合し、各段落に関連度スコアを付けます。

絞り込み

スコア上位の段落を残し、類似度のしきい値を下回る段落を除外してから、大規模言語モデルに渡します。

MaiAgent での Reranker の使い方

ナレッジベースごとに Reranker モデルを選択し、**検索結果の並べ替えを有効にする (Reranking)** スイッチで有効・無効を切り替えます（デフォルトは有効です）。

有効な場合、第1段階で **検索する段落数** × プラットフォームで設定された倍率（デフォルトは7倍）の候補を取得します。Reranker で並べ替えた後、**検索する段落数** の件数だけを残します。

類似度のしきい値 (0～1) は Reranker のスコアに適用されるため、Reranker が有効な場合のみ機能します。

無効な場合、第1段階で直接 **検索する段落数** の件数を取得し、並べ替えも類似度のしきい値の適用も行いません。

全体の流れは [RAG ナレッジベース検索システム](#) をご覧ください。

MaiAgent クラウドで有効なモデル

以下は2026年10月時点で本番環境で有効なモデルの一覧です。ナレッジベース作成時に選択できるモデルは、管理画面の表示をご確認ください。

モデル（管理画面での名称）	プロバイダー
Cohere Rerank v3.5	Cohere (rerank-v3.5)
Cohere Rerank v4 Pro	Cohere (rerank-v4.0-pro)
Cohere Rerank v4 Fast	Cohere (rerank-v4.0-fast)

オンプレミスへのデプロイ

オンプレミスやプライベートクラウドでは、Reranker をローカルにデプロイできます（デプロイパッケージのモデルカタログには `jina-reranker-v2-base-multilingual` と `bge-reranker-v2-m3` が含まれ、GPU が必要です）。既存のモデルサービスやクラウドプロバイダーへの接続も可能です。利用可能なモデルと接続方法は [オンプレミスのモデルサービス接続](#) を、各クラウドプロバイダーの Reranker 対応状況は [クラウドモデル推論 API サービス](#) をご覧ください。

自前の Reranker サービスを使用する場合、URL に /v1 を付けないでください。付けると、ナレッジベース検索がすべて失敗します。URL のルールは [オンプレミスのモデルサービス接続：既存の OpenAI 互換モデルサービスへの接続](#) をご覧ください。

Parser 解析ツール

Parser とは？

Parser（パーサー）は、ナレッジベースにアップロードされた元のファイルをテキストに変換し、ベクトル化と検索の前処理を行います。解析の品質は、その後に必要な内容を見つけられるかどうか直結します。テーブルの構造が保持されるか、画像やスキャンページ内の文字が読み取られるかは、この段階で決まります。

RAG の処理フロー

アップロード時にファイルごとにパーサーを指定できます。管理画面での操作は、ユーザーマニュアルの [ナレッジベースの作成方法：基本設定](#) をご覧ください。各パーサーで利用できるファイル形式は、[GET /api/v1/allowed-file-specs/](#) でも取得できます。

文書パーサー

MaiAgent クラウドでは、現在 3 種類の文書パーサーを提供しています。

項目	MaiAgent Parser（デフォルト）	MaiAgent Parser (Offline)	Vision Parser
処理方法	ファイル内のテキスト、テーブル、画像を直接読み取ります	レイアウト解析によって文書構造（見出し、テーブル）を保持します	クラウドのマルチモーダルモデルが文書をページごとに視覚的に読み取り、Markdown に変換します
画像とスキャンページ	埋め込み画像を抽出します。テキストレイヤーのないベクトル図形のページには OCR を実行します	マルチモーダルモデルを設定すると、PDF に OCR と画像説明を追加します	視覚理解によって画像、グラフ、スキャンページの内容を読み取ります
大規模言語モデルの使用	しません	マルチモーダルモデルを設定した場合のみ使用します	使用します
オフライン（ネットワークなし）環境	利用できます	利用できます。画像説明にはオンプレミスのマルチモーダルモデルが必要です	利用できません。クラウドモデルへの接続が必要です
対応形式	.pdf.doc.docx.odt.xls .xlsx.csv.ods.ppt.pptx .odp.epub.txt.json.jsonl	.pdf.docx .pptx.md .html.htm	.pdf.doc.docx .odt.ppt.pptx .odp

項目	MaiAgent Parser（デフォルト）	MaiAgent Parser (Offline)	Vision Parser
	.md .eml および画像ファイル .png .jpg .jpeg .gif .webp .tiff		

画像ファイル（**.png**、**.jpg** など）をナレッジベースに追加するには、マルチモーダルに対応した Embedding モデルを使用する必要があります。[Embedding モデル](#) をご覧ください。

MaiAgent Parser (Online) は現在、プラットフォーム全体で無効化されており、選択できません。

オンプレミス環境で利用できるパーサーはデプロイ設定によって異なります。MaiAgent の担当者にお問い合わせください。

Gemini 画像認識パーサー

上記の 3 種類に加えて、**Gemini 3.1 Pro Preview**（Google Vertex AI 経由）で画像認識（OCR）を行うパーサーを有効にすることもできます。対応形式は Vision Parser と同じです（**.pdf**、Word、PowerPoint、OpenDocument 文書。Office ファイルは先に PDF に変換されます）。

項目	説明
処理方法	PDF 全体を一度にモデルへ送信して認識し、ページごとには分割しません
ファイルごとの上限	50 MB または 1,000 ページです
文書全体の認識に失敗した場合	自動的に 50 ページずつに分けて再送信します
課金	モデルの実際の入力・出力使用量に応じて Credits を消費し、消費履歴には同様に Vision parsing input: ファイル名 、 Vision parsing output: ファイル名 と記録されます
オフライン（ネットワークなし）環境	利用できません。Vertex AI への接続が必要です

デフォルトのパーサーと「自動検出（デフォルト）」の選択ルールは変わりません。必要に応じて、アップロード画面または文書一覧の **パーサー** ドロップダウンから手動で選択してください。パーサー一覧はプラットフォーム側で設定されます。この選択肢が表示されない場合は、MaiAgent の担当者にお問い合わせください。

「自動検出（デフォルト）」と解析の課金

PDF、Word（.docx）、PowerPoint（.pptx）をナレッジベースにアップロードする際、アップロード画面の各ファイル横にあるパーサーのドロップダウンは、デフォルトで **自動検出（デフォルト）** になっています。常に MaiAgent Parser を使うわけではありません。アップロード後にファイル構造を読み取り、パーサーを決定します。

テキストのみで、明確な画像コンテンツがないファイル → そのファイル形式のデフォルトパーサー（通常は MaiAgent Parser）を使用します。

スキャンファイル（テキストレイヤーなし）、画像コンテンツを含むファイル（設計図やスキャン文書など）、PowerPoint → OCR または視覚理解に対応したパーサー（MaiAgent Parser (Offline)、Vision Parser）から選択します。適切なパーサーが見つからない場合は、デフォルトパーサーを使用します。

判定基準はファイル構造（テキストレイヤーの有無、画像やテーブルを含むページ数）であり、画像の枚数ではありません。Word ファイルは、画像が埋め込まれていれば画像コンテンツを含むものとして扱われます。そのため、画像が少ない文書でも上記のパーサーに切り替わる場合があります。実際に使用されたパーサーは、ナレッジベースの文書一覧にある **パーサー** 列で確認してください。

ポイントは、**実際に解析を完了したパーサー**に基づいて計算されます。各パーサーの課金単位、再解析やパーサー変更時のポイント消費ルールは、ユーザーマニュアルの **使用量の計算：各パーサーの課金単位** をご覧ください。照合時には、各解析料金が組織の Credits の **消費履歴** に以下の説明で記録されます（エクスポートした CSV の「説明」列です。**検索** にファイル名を入力して調べることもできます）。

パーサー	消費履歴の説明
MaiAgent Parser	Document parsing (maiaagent): ファイル名
MaiAgent Parser (Offline)	Document parsing (docling): ファイル名
Vision Parser	Vision parsing input: ファイル名 、 Vision parsing output: ファイル名

文書一覧でパーサーを変更すると（**パーサーの一括変更**を含む）、確認画面なしで直ちに再解析されます。解析コストを一定に保ち、他のパーサーへの自動切り替えを避けるには、アップロード時に MaiAgent Parser（または指定のパーサー）を直接選択し、**自動検出（デフォルト）** は使用しないでください。

大きすぎる画像による解析の失敗

文書に埋め込まれた画像にはサイズ上限があり、超過した場合の挙動はパーサーによって 2 種類に分かれます。

Vision Parser は、一辺が 8,000 px を超える、または総画素数（幅 × 高さ）が 4,000 万を超える埋め込み画像をスキップし、ページ全体の画像のみを認識します。文書全体の解析が失敗することはありません。スキップされた画像に重要な内容がある場合は、画像を縮小してから再アップロードしてください。

その他のパーサーでは、巨大な画像のデコード時に文書全体の解析が失敗する場合があります。文書一覧の **失敗理由** に `total decoded image size must be at most ... pixels` などのメッセージが表示された場合、文書内の画像の総画素数が、そのパーサーのデコード上限を超えています。元の文書内の画像を縮小または圧縮して再アップロードしてください。スキャンファイルは Vision Parser に切り替え、テキストだけが必要な場合は画像なしの文書を別途保存してください。

上限はファイルサイズではなく総画素数で計算されます。8,000 × 8,000 のスクリーンショット（6,400 万画素）は、小さな JPEG に圧縮しても上限を超えます。縮小時は長辺を 4,000 px 以内に収めると最も確実です。

音声文字起こしパーサー

音声ファイルをナレッジベースにアップロードすると、音声文字起こしパーサーが文字起こしテキストに変換し、その後にインデックスを作成します。MaiAgent クラウドでは現在、以下を提供しています。

パーサー（管理画面の名称）	サービス	言語設定	カスタムプロンプト	動画ファイルのアップロード
Azure Speech	Azure 音声サービス	最大 4 言語を指定できます	不可	不可
WhisperGroq	Groq（Whisper large-v3）	1 言語を指定、または自動検出できます	可	可
WhisperOpenAI	OpenAI（Whisper）	1 言語を指定、または自動検出できます	可	可
Bronci（長問語音認識）	Bronci	台湾語、台湾華語、客家語（四県、海陸）から 1 つ選択します	不可	不可

音声文字起こしは音声の秒数に応じて課金され、再文字起こしのたびに料金が発生します。ユーザーマニュアルの 使用量の計算：各パーサーの課金単位 をご覧ください。消費履歴の説明は **Audio parsing（サービスコード）：ファイル名** で、たとえば **Audio parsing（azure）：ファイル名** と記録されます。

オンプレミス環境の音声文字起こしは、デプロイパッケージで設定されます。新規デプロイでは、デフォルトでローカルの LocalAI サービスを使用します（モデルは Qwen3-ASR または Whisper で、GPU が必要です）。既存の環境では Whisper (Offline) を引き続き使用できます。どちらもオンプレミスで実行され、音声クラウドに送信されることはありません。

音声の解析が完了すると、ナレッジベースで文字起こしテキストを確認し、TXT（プレーンテキスト）または SRT（字幕形式）でダウンロードできます。

画像認識サポート

VLM（Vision Language Model）とは？

視覚言語モデル（Vision Language Model、VLM）は、画像とテキストを同時に理解できます。画像内の文字を認識するだけでなく、物体、表、グラフ、それらの関係も理解し、画像の内容に基づいて質問に回答したり、説明を生成したりできます。

VLM と従来の OCR の比較

従来の光学文字認識（OCR）は、画像から文字を見つけて抽出することに特化しています。画像全体の意味や文字以外の内容を理解するうえでは、できることが限られています。

特性	従来の OCR	VLM
主な機能	画像から文字を抽出します	画像の内容を理解し、テキスト情報と組み合わせます
処理範囲	文字のみを処理します	文字、物体、グラフ、レイアウトを処理します
理解のレベル	文字を認識します	シーン、関係性、文脈を理解・推論します
一般的な用途	ドキュメントのスキャンや文字抽出に使用します	画像に関する質疑応答、グラフの解釈、画像の説明に使用します

MaiAgent が画像を処理する場面

会話に添付された画像

ユーザーが会話で画像をアップロードすると、画像は Agent の大規模言語モデルに直接渡され、内容が解釈されます。そのため、Agent はマルチモーダル対応のモデルを使用する必要があります。モデルが対応していない場合、応答に「選択した LLM はマルチモーダルに対応していません。」と表示されます。対応モデルについては、ユーザーマニュアルの[モデルの利用権限](#)をご覧ください。

1回のリクエストでモデルに送信できる画像数には上限があり、プラットフォームの設定で決まります（デフォルトは20枚です）。API でアップロードする場合、添付ファイルの `type` を `image` にすると、画像が視覚入力としてモデルに送信されます。`other` にすると、代わりにドキュメント解析フローで処理されます。[メッセージの添付ファイルの処理方法](#)をご覧ください。

ナレッジベースのドキュメント内の画像とスキャンページ

PDF、Word、PowerPoint などのドキュメントに含まれる画像、グラフ、スキャンページは、パーサーで内容を読み取ることで検索できるようになります。

Vision Parser：クラウドのマルチモーダルモデルでドキュメントを1ページずつ読み取り、画像、グラフ、スキャンページの内容をテキストに変換します。

MaiAgent Parser (Offline)：マルチモーダルモデルを設定すると、PDF に対して OCR と画像の説明生成も行います。オフラインでの運用が必要な環境に適しています。

MaiAgent Parser：埋め込み画像を抽出しますが、画像の内容はテキストに変換しません。ナレッジベースがマルチモーダル対応の Embedding モデルを使用している場合、抽出された画像自体もベクトルインデックスに登録されます。

アップロード時に **自動検出 (デフォルト)** を選択すると、スキャンファイルや画像を含むドキュメントには、上記の画像を処理できるパーサーが使用されます。各パーサーの違いと料金は [Parser 解析ツール](#) をご覧ください。

ナレッジベースの画像ファイル

画像ファイル（**.png**、**.jpg**、**.jpeg**、**.gif**、**.webp**、**.tiff**）は、ナレッジベースに直接アップロードし、画像自体をベクトルインデックスに登録できます。ナレッジベースでマルチモーダル対応の Embedding モデル（MaiAgent クラウドでは Cohere Embed V4.0）を使用する必要があり、対応していない場合はファイルの解析に失敗します。[Embedding モデル](#) をご覧ください。

3つの場面はそれぞれ独立しています。Agent のモデルがマルチモーダルに対応していても、ナレッジベースで画像ファイルを処理できるとは限りません。逆も同様です。導入を計画する際は、Agent のモデル、ナレッジベースのパーサー、Embedding モデルをそれぞれ確認してください。

技術原理

システムプロンプト

最終更新：2026-10-04

システムプロンプト（System Prompt）は、Agent が毎回の回答で従うルールを記述したものです。書き方、テンプレート、例については、ユーザーマニュアルの[システムプロンプト設計ガイド](#)をご覧ください。

本ページでは、もう一方の要素を説明します。プラットフォームは各回答前に、Agent と会話プラットフォームの設定に応じて「現在のコンテキスト」をシステムプロンプトの後に自動的に追加し、まとめてモデルに送信します。これらの内容はシステムが毎回生成するため、システムプロンプトに固定で書き込む必要はなく、書き込むべきでもありません。

モデルに送信するシステムプロンプトの構成

回答のたびに、プラットフォームは以下の順序で組み合わせます。

作成したシステムプロンプト。グループ会話では、プラットフォームのグループ会話用指示を先に配置し、その後作成したシステムプロンプトを続けます。

引用マーカースの指示：Agent の **インライン引用を有効にする** が有効な場合、回答に **[1][2]** の引用マーカースを挿入するルールを追加します。

プラットフォームが追加するコンテキスト：時間、ユーザー名、位置、言語、カスタム属性などです。[次の節](#)を参照してください。

状況に応じて追加するガイダンス：ユーザーがスキルを指定した場合や、ナレッジベースが一時的に利用できない場合などです。[状況に応じて追加するガイダンス](#)を参照してください。

追加した内容はその回答でのみ使用し、Agent のシステムプロンプト設定には書き戻しません。

プラットフォームが追加するコンテキスト

追加する内容	追加する条件	値の取得元
現在の時間： タイムゾーン、日時、曜日、週番号、UTC オフセット	会話プラットフォームの システム時間を使って回答する が有効で、タイムゾーンを取得できる場合	メッセージ metadata の timezone を使用します。指定がない場合は、会話プラットフォームの タイムゾーン 設定を使用します。どちらもない場合は追加しません。各プラットフォームのタイムゾーンの取得元については、ユーザーマニュアルの タイムゾーンの決定方法 をご覧ください
ユーザー名	会話プラットフォームの 送信者名を使って回答する が有効で、名前がある場合	連絡先の名前を使用します。組織メンバーが管理画面で会話する場合は、メンバー名を使用します

追加する内容	追加する条件	値の取得元
現在の位置 ：座標、および精度（提供されている場合）	会話プラットフォームの 位置情報を使って回答する が有効で、メッセージに <code>latitude</code> と <code>longitude</code> が含まれる場合	Web Chat はブラウザーの位置情報取得の許可を得た後、メッセージに位置情報を含めます。API では呼び出し元がメッセージ metadata に設定します
ユーザーの言語 ：ユーザーの希望言語を判断できない場合、この言語で回答するようモデルに指示します	メッセージに言語情報が含まれる場合	Web Chat と API で作成したメッセージでは、metadata の <code>language</code> 、リクエストの <code>Accept-Language</code> の順に取得し、どちらもない場合はプラットフォームのデフォルト言語を使用します
連絡先のカスタム属性	連絡先にカスタム属性がある場合、またはメッセージ metadata にカスタムキーが含まれる場合	連絡先のカスタム属性と、そのメッセージの metadata を組み合わせます（同じキーがある場合はメッセージ側を優先します）。 <code>timezone</code> 、 <code>latitude</code> 、 <code>longitude</code> 、 <code>accuracy</code> 、 <code>locale</code> 、 <code>language</code> 、 <code>contact_name</code> などの予約済みキーは含めません。Web Chat にページの context を注入する方法については、 Web Chat へのページ Context の注入 をご覧ください
組織メンバーの属性	送信者が組織メンバーで、カスタム属性が設定されている場合	組織内のメンバーのカスタム属性を使用します。ユーザーマニュアルの 個人プロフィール：カスタム属性 をご覧ください
ナレッジベースのガイダンス ：ナレッジベースで回答できる可能性がある質問では、ユーザーに追加質問する前にナレッジベースを検索するようモデルに指示します	Agent モードで、その会話に利用可能なナレッジベースがある場合	Agent に接続されたナレッジベースの数に基づきます
開始メッセージと開始オプション	通常モードで会話に開始メッセージがある場合、そのメッセージを追加します。Web Chat の 開始オプションを Agent のコンテキストに含める が有効な場合、開始メッセージと番号付きの会話開始用質問を追加します	会話で実際に送信した開始メッセージと会話開始用質問を使用します。ユーザーマニュアルの 開始オプションを Agent のコンテキストに含める をご覧ください
添付ファイルの処理ガイダンス ：ユーザーがアップロードした添付ファイルを、どのツールで読み取るかを示します	Agent モードの場合	Agent で有効な添付ファイル用ツールに基づきます
Code Interpreter の使用ガイダンス	Agent モードで、Agent の Code Interpreter が有効な場合	プラットフォームに組み込まれた使用ルールです。ユーザーマニュアルの Code Interpreter を参照してください

追加する内容	追加する条件	値の取得元
利用可能なスキル一覧：各スキルの名称と使用するタイミング	Agent にスキルが紐付けられている場合	スキルの使用条件（未入力の場合は説明）を、スキル展開ツールの説明とともにモデルに提供します。完全な指示はモデルがスキルを展開してから読み込みます。 Skill スキルモジュール を参照してください

追加するブロックは、`Current time information`、`Current user information`、`Current location`、`Contact custom attributes`、`Organization member attributes` など、固定の英語見出しで始まります。システムプロンプトでこれらの情報を使用するようモデルに指示する際は、見出しをそのまま参照できます。例えば、「Contact custom attributes に productId がある場合、ユーザーはその商品を閲覧しています。まずこの ID を使って商品を検索してください」と記述できます。

プロンプトキャッシュ（prompt caching）に対応したモデルを使用する場合、毎回変わる時間と位置情報はブロックにまとめ直し、最後のメッセージの後に配置します。これにより、回答のたびに前方のキャッシュが無効になることを防ぎます。内容は上の表と同じで、配置位置だけが異なります。

状況に応じて追加するガイドンス

以下のガイドンスは特定の状況でのみ表示され、機能が制限されている場合にモデルが情報を作り上げることを防ぎます。

ユーザーがスキルやツールを指定した場合：そのメッセージでユーザーがスキルやツールを指定している場合、指定されたものを先に使用してから回答するようモデルに指示します。

ユーザーが参照ドキュメントを選択した場合：MaiGPT で参照ドキュメントを選択している場合、選択されたナレッジベースを先に検索するようモデルに指示します。回答が見つからない場合に限り、他のツールや一般知識を使用し、選択されたドキュメントに回答がないことを説明します。

ナレッジベースが一時的に利用できない場合：すべてのナレッジベースへの接続が失敗した場合、ユーザーに後で再試行するよう伝えることをモデルに指示します。ナレッジベースから取得すべき内容を記憶に基づいて回答してはいけません。

利用枠不足で Reranker をスキップした場合：Agent の Reranker が有効でも、組織の Credits が不足してスキップした場合、今回の検索結果の順位が通常より不正確な可能性があることをモデルに伝えます。

メンバーのロールで一部の組み込み機能が無効な場合：MaiGPT で、メンバーのロールに一部の組み込み機能の利用権限がない場合、利用できない機能をモデルに伝えます。

システムプロンプト作成時の注意点

システムプロンプトに日付や時間を固定で書き込まないでください。時間が必要な場合は **システム時間を使って回答する** を有効にしてください。固定で書き込んだ日付は、システムが追加する時間と矛盾します。

変動するユーザーデータをシステムプロンプトに書き込まないでください。名前、現在の位置、会員ランクなどは、上の表の追加コンテキストから取得します。システムプロンプトには「そのデータを取得した場合にどう使うか」だけを記述してください。

ユーザーが実際に使用している会話プラットフォームで設定を有効にしてください。時間、名前、位置の3つの切り替えは会話プラットフォームごとに個別に設定します。例えば、問題がLINEで発生している場合は、LINEプラットフォームの切り替えを有効にしてください。

システムプロンプトで、誰がどのドキュメントを閲覧できるかを制御しないでください。次の節を参照してください。

ドキュメントの閲覧範囲はシステムプロンプトではなく Query Metadata で制御します

システムプロンプトが影響を与えられるのは、AIが「すでに検索された」内容をどう使うかだけであり、検索自体を防ぐことはできません。システムプロンプトに「一般の顧客は内部ドキュメントを参照してはいけません」と書いても、そのドキュメントは検索され、LLMのコンテキストに送信されます。AIがそのまま引用したり、プロンプトインジェクションによって内容を開示するよう誘導されたりする可能性があります。

「どのユーザーがどのドキュメントを検索できるか」を制限するには、Query Metadata (クエリメタデータ)を使用してください。連絡先、会話、メッセージに、検索可能なナレッジベース、ドキュメント、タグの条件を設定します。システムが検索時に条件で絞り込むため、範囲外のドキュメントは取得されず、LLMにも送信されません。アクセスレベルなどの条件には、ナレッジベースのタグでドキュメントを分類し、Query Metadataのタグ条件で制御してください。

システムプロンプトは、口調、回答手順、優先順位の指定に適しています。「特定の人に特定のデータを見せない」という要件は、すべて Query Metadata で処理してください。システムが強制的に適用するその他の保護機構については、AI 安全保護機構をご覧ください。

関連リソース

システムプロンプト設計ガイド：書き方、テンプレート、例

機能設定：AI 認識設定：時間、名前、位置の3つの切り替えの管理画面での操作

Web Chat へのページ Context の注入：Web ページから連絡先のカスタム属性を渡す方法

クエリメタデータ：ユーザーが検索できるドキュメントの制限

回答の評価とモニタリング結果

MaiAgent は、運用開始後に回答ごとにスコアを算出する **Agent モニタリング**と、テストセットを使って一括実行する**自動評価**の 2 つの方法で Agent の回答品質を評価します。本ページでは、それぞれの指標と計算方法を説明します。管理画面で評価を作成し、結果を確認する操作については、ユーザーマニュアルの**自動評価と Agent モニタリング**をご覧ください。ご自身のシステムからテストセットを作成し、評価を実行して結果を取得する方法については、API ドキュメントの**評価とテストセット**をご覧ください。

2 つの評価方法の違い

項目	Agent モニタリング	自動評価
評価対象	実際の会話における各回答	テストセットの質問に Agent が実際に回答した後、採点します
有効にする方法	Agent の 自動評価を有効にする	AgentOps で評価を作成します
採点フレームワーク	Ragas	DeepEval (4.1.7)
採点に使用するモデル	プラットフォームに設定された評価モデル	評価作成時に選択する 評価モデル
指標	固定の 3 項目（以下を参照）	組み込み指標を組み合わせ、カスタム指標も追加できます
費用	採点には組織の利用枠を消費します	回答と採点の両方で組織の利用枠を消費します

オンプレミス環境では、Agent モニタリングが使用する評価モデルと Embedding モデルをプラットフォームのシステム設定で指定します。オンプレミス環境から接続できるモデルを指定しないと、採点が失敗します。

Agent モニタリングの指標

Agent の **自動評価を有効にする** を有効にすると、回答が完了するたびにプラットフォームがバックグラウンドで以下のスコアを計算し、Agent モニタリングに結果を表示します。

指標	判定内容
Faithfulness（忠実度）	回答の内容すべてに、検索された文章内で根拠が見つかるかを判定します

指標	判定内容
Answer Relevancy（回答の関連性）	回答が質問に的確に答えているかを判定します
Context Precision（コンテキストの適合率）	検索された文章と質問の関連度を判定します。期待する回答は不要です

実際の会話には期待する回答がないため、モニタリングでは期待する回答が必要な指標を計算しません。

自動評価の指標

シングルターン評価

Agent が各質問に実際に回答した後、以下の指標で採点します（管理画面に表示される名称は「管理画面の名称」欄を参照してください）。

指標	管理画面の名称	判定内容	管理画面で評価を作成する場合
Faithfulness	品質スコア	回答が検索された文章に忠実かを判定します	常に計算します
Answer Relevancy	回答の関連性	回答が質問に答えているかを判定します	常に計算します
Contextual Precision	コンテキストの適合率	関連する文章が上位に並んでいるかを判定します	常に計算します（期待する回答が必要です）
Contextual Relevancy	コンテキストの関連性	検索された文章全体と質問の関連度を判定します	常に計算します（期待する回答が必要です）
Contextual Recall	コンテキストの再現率	期待する回答に必要な情報がすべて検索されているかを判定します	常に計算します（期待する回答が必要です）
Bias	バイアス	回答にバイアスが含まれるかを判定します	常に計算します
Toxicity	有害性	回答に不適切または有害な内容が含まれるかを判定します	常に計算します
Hallucination	ハルシネーション	回答が検索された内容と矛盾するかを判定します	常に計算します
PII Leakage	PII 漏えい	回答が個人識別情報を漏えいしているかを判定します	任意（安全性指標）
Role Violation	役割違反	回答が Agent 本来の役割から逸脱しているかを判定します	任意（安全性指標）
Misuse	不正利用	Agent が想定外の用途に使用されているかを判定します	任意（安全性指標）

指標	管理画面の名称	判定内容	管理画面で評価を作成する場合
Non-Advice	専門的助言の回避	回答が医療、法律、金融などの専門的助言を避けているかを判定します	任意（安全性指標）

管理画面で作成するシングルターン評価では、コンテキストに関する3つの指標を計算するため、すべての質問に期待する回答が必要です。期待する回答が入力されていない質問はスキップ済みと表示され、回答も採点も行いません。

プラットフォームの評価サービスは、Task Completion、Tool Correctness、Summarization の3つの指標にも対応していますが、管理画面で評価を作成する場合には有効になりません。

マルチターン評価

マルチターン評価では、シミュレーションユーザーがテストケースのシナリオに沿って Agent と会話し（最大ターン数は2〜10、デフォルトは6）、以下の指標で採点します。少なくとも1つの組み込み指標を有効にするか、カスタム指標を設定する必要があります。

指標	判定内容
ターンごとの忠実度（Turn Faithfulness）	各ターンの回答が検索された内容に忠実かを判定します
ターンごとの関連性（Turn Relevancy）	各ターンの回答が質問に答えているかを判定します
会話の完遂度（Conversation Completeness）	会話全体がユーザーの目標を達成したかを判定します

カスタム指標（GEval）

シングルターン評価とマルチターン評価のどちらにもカスタム指標を追加できます。自然言語で評価基準を記述するか、評価ステップを列挙すると、評価モデルが基準に沿って0〜1のスコアを付けます。

制限	ルール
数量	1回の評価につき最大10個です
名称	最大100文字です。同じ評価内で重複できません（大文字と小文字は区別しません）。また、そのモードの組み込み指標と同じ名称は使用できません
評価基準	最大2,000文字です
評価ステップ	最大10件、各ステップは最大500文字です
合格しきい値	0〜1、デフォルトは0.5です

シングルターン評価のカスタム指標は、質問、Agent の回答、検索された文章に基づいて採点します。マルチターン評価のカスタム指標は、会話全体の文字起こしに基づいて採点し、検索された文章は参照しません。

スコアの方向性と合否判定

スコアの範囲は 0～1 です。組み込み指標には DeepEval のデフォルトの合格しきい値 0.5 を使用します。各テストケースのスコアは DeepEval の元の方向性を維持します。**バイアス、有害性、ハルシネーション、不正利用はスコアが低いほど良く**、その他の指標は高いほど良くなります。評価の統計値では、この 4 つを「1-スコア」に換算し、すべての統計値で高いほど良くなるようにします。

シングルターン評価で質問の合否を判定する際は、以下の 3 グループの主要指標を順番に確認します。いずれかのグループで 1 つでも指標がしきい値を満たさなければ、その質問は不合格です。

安全性：バイアス、有害性、ハルシネーション、PII 漏えい、役割違反、不正利用、専門的助言の回避

成果：回答の関連性（および Task Completion）

根拠：コンテキストの再現率

その他の指標（品質スコア、コンテキストの適合率、コンテキストの関連性、カスタム指標など）もしきい値を満たす必要があります。上記の 3 グループすべてが計算され、すべて合格している場合に限り、その他の指標がしきい値を満たさなくても合否には影響しません。

不安定（flaky）とマークされた質問も実行して結果を保存しますが、合格率には含めません。

Faithfulness と Hallucination の違い

どちらも回答と検索された内容の関係を確認しますが、観点が異なります。

観点	Faithfulness（品質スコア）	Hallucination（ハルシネーション）
評価する問い	回答中のどれだけの記述が、検索された内容に根拠を持つかを評価します	回答が検索された内容と矛盾するかを評価します
スコアの方向性	高いほど良くなります	各テストケースのスコアは低いほど良くなります

例えば、検索された内容が「台北 101 の高さは 508 メートルで、2004 年に完成しました」で、回答に「かつて世界で最も高い建物でした」という一文が追加されている場合です。この一文には検索された内容に根拠がないため、Faithfulness が下がります。一方、Hallucination は回答が検索された内容と矛盾していないかを確認します。

スコアが低い場合の確認ポイント

コンテキストの再現率や適合率が低い場合： 検索で正しい文章が見つかりません。まず 検索テスト で確認し、ナレッジベースの内容、パーサー、検索パラメータを調整してください。RAG ナレッジベース検索システム

△を参照してください。

品質スコアが低く、コンテキストのスコアは正常な場合：文章は見つっていますが、回答がその文章に基づいていません。システムプロンプトを確認するか、より高性能なモデルに変更してください。

回答の関連性が低い場合：回答が質問に的確に答えていません。システムプロンプトの制約が厳しすぎる場合や、質問がナレッジベースの範囲外の場合によく発生します。

スコア全般が不安定な場合：採点自体は評価モデルの判断に依存します。より高性能な評価モデルを選択してください。

Text to SQL

Text to SQL は、Agent がユーザーの自然言語による質問を SQL に変換し、接続先のデータベースを検索して、結果に基づいて回答する機能です。このページは、データベース管理者と技術担当者向けの仕様説明です。データベース接続の作成と Agent への関連付けの手順は、ユーザーマニュアルの [Text to SQL 機能とデータベースの作成と設定](#) をご覧ください。

動作方式

Text to SQL は、Agent が **Agent モード** を使用している場合のみ有効です。Agent は必要に応じて、次のツールを順に呼び出します。

クエリ可能なデータベースを一覧表示します（1 つの Agent に複数のデータベースを関連付けられます）。データベース内のクエリ可能なテーブルとビュー、および入力されたテーブルの説明を一覧表示します。特定のテーブルのカラム構成とカラムの説明を読み取ります。SQL クエリを実行し、結果を取得して回答します。

各クエリで返す行数は、プラットフォームの設定値が上限です（デフォルトは 1,000 行）。上限を超える場合は先頭の行だけを返し、結果が切り詰められたことをモデルに通知します。接続の切断などの一時的なエラーは自動で再試行します。SQL の構文エラーや権限エラーは、エラーメッセージをそのままモデルに渡し、モデルがクエリを修正します。

対応データベース

種類	接続文字列の形式	説明
MaiAgent データベース	不要です	スプレッドシートなどのファイルをアップロードしてテーブルを作成し、プラットフォームが管理します。ユーザーマニュアルの MaiAgent データベースでの Text to SQL をご覧ください
PostgreSQL	<code>postgresql://ユーザー名:パスワード@ホスト:ポート/データベース</code>	<code>postgres://</code> で始まる形式に

種類	接続文字列の形式	説明
		も対応します
MySQL	mysql+pymysql://ユーザー名:パスワード@ホスト:ポート データベース	
Microsoft SQL Server	mssql+pyodbc://ユーザー名:パスワード@ホスト:ポート データベース? driver=ODBC+Driver+18+for+SQL+Server&TrustServerCertificate=yes&Encrypt=no	プラットフォームに ODBC Driver 18 for SQL Server を組み込んでいます
Oracle	oracle+oracledb://ユーザー名:パスワード@ホスト:ポート ?service_name=サービス名	Oracle Database 12.1 以降に対応します。11g はプラットフォームで Oracle Client を追加で有効にする必要があります。MaiAgent の担当者にお問い合わせください
SynxDB	postgresql://ユーザー名:パスワード@ホスト:ポート データベース	PostgreSQL 互換の MPP データウェアハウスです

接続文字列の先頭は、選択した種類と一致する必要があります。一致しない場合は保存できません。作成時に **接続テスト** をクリックすると、プラットフォームからデータベースに接続できるか確認できます。

接続のセキュリティ

読み取り専用の保護

プラットフォームは、2つの層でクエリを読み取り専用に制限します。

構文チェック： **SELECT** のみ許可します（**WITH**、**UNION** などの読み取り構文を含みます）。**INSERT**、**UPDATE**、**DELETE**、**MERGE**、**CREATE**、**ALTER**、**DROP**、**TRUNCATE**、**SELECT ... INTO**、およびセミコロンで連結した複数のステートメントはブロックします。

読み取り専用トランザクション： PostgreSQL、MySQL、Oracle のクエリは読み取り専用トランザクションで実行し、データベース自体が書き込みを拒否します。SQL Server には同等の読み取り専用セッション設定がな

いため、プラットフォームは「クエリ後に必ずロールバックし、コミットしない」方式で処理します。この方式の保護は比較的弱くなります。

必ず読み取り専用アカウントで接続してください。プラットフォームの保護は第二の防御策です。データベースアカウントに必要なテーブルやビューの読み取り権限のみを付与することが、最も直接的な制御となります。SQL Server では特に重要です。

アカウントと接続文字列

MaiAgent 専用のアカウントを作成し、クエリが必要なテーブルやビューの `SELECT` 権限のみを付与することをおすすめします。

接続文字列にはユーザー名とパスワードが含まれます。保存後に読み取ると、マスクされた内容のみ表示します。変更する場合は、接続文字列全体を再入力してください。

データベースを Agent に関連付けられるユーザーや、使用できるロールは、データベースのロール権限設定に従います。[データベースの作成と設定](#)をご覧ください。

ネットワーク要件

データベースは MaiAgent プラットフォームから接続する必要があります。プラットフォームからデータベースのホストとポート（接続文字列に記載したアドレス）に接続します。[接続テスト](#)をクリックしたときと、各クエリの実行時に接続を確立します。

ポートは接続文字列に従います。各データベースのデフォルト値は、PostgreSQL 5432、MySQL 3306、SQL Server 1433、Oracle 1521、SynxDB 5432 です（デプロイ設定によります）。

SaaS：データベースは MaiAgent プラットフォームの送信元アドレスからの接続を許可する必要があります。ファイアウォールの許可リストを設定する場合は、MaiAgent の担当者へ送信元 IP をお問い合わせください。

オンプレミスとプライベートクラウド：プラットフォームとデータベースを同じネットワークセグメントに配置するか、VPN など相互に接続できるようにする必要があります。

大規模な schema の処理

プラットフォームは schema 全体を一度にモデルに送信しません。モデルは最初にテーブル一覧と説明を取得し、必要に応じて個々のテーブルのカラム構成を読み取ります。テーブルが多い場合は、次の方法をおすすめします。

テーブルの指定で範囲を絞ります：質問への回答に必要なテーブルのみ公開します。空欄の場合、デフォルト schema 内のすべてのテーブルとビューをクエリできます。

別の schema のテーブルには schema 名を記載します：例えば `sales.orders` です。プラットフォームは、デフォルト schema と指定テーブルに含まれる schema のみをスキャンします。

テーブル構造の説明を入力します：テーブルの用途とカラムの意味を説明すると、モデルが適切なテーブルとカラムを選びやすくなります。

あらかじめビューを作成します：よく使う結合（JOIN）と業務ロジックをビューにまとめ、ビューだけを公開すると、クエリの誤りと権限リスクの両方を減らせます。

よくある質問

- ▶ 接続テストが失敗する場合は？
- ▶ API で特定のテーブルの行数を取得するには？
- ▶ Agent は Text to SQL でデータを変更できますか？
- ▶ Query Metadata は Text to SQL を制限しますか？
- ▶ Agent の設定ページにデータベース設定が表示されない場合は？

Function Calling

Function Calling とは？

Function Calling（関数呼び出し、またはツール呼び出し）とは、大規模言語モデル（LLM）がリクエストを処理する際に、外部プログラムや API（以下、まとめて「ツール」と呼びます）が必要だと判断し、呼び出すツールの名前と引数を構造化された形式（通常は JSON）で出力することです。

LLM 自体はツールを実行せず、どのツールをどの引数で呼び出すかを「決定」するだけです。実際の実行は呼び出し元のプログラムが行い、結果を LLM に返します。LLM はその結果に基づいて回答するか、次のツールを呼び出すかを決定します。



LLM が必要に応じて検索、天気 API、翻訳 API などのツールを選択します

LLM がユーザーの要望に応じて呼び出すツールを選択します（概念図）

Function Calling の仕組み

一般的に、Function Calling は次のサイクルで動作します。

- ツール定義の提供：**呼び出し元が各ツールの名前、用途の説明、パラメーター構造（JSON Schema）を、会話とともに LLM に送信します。
- モデルによる呼び出しの決定：**LLM がツールを必要と判断すると、直接回答する代わりにツール名と JSON 形式の引数を出力します。
- ツールの実行：**呼び出し元が名前と引数に従って対応するプログラムを実行します。例えば、データベースの照会や外部 API の呼び出しです。
- 結果の返却：**呼び出し元が実行結果を会話に追加し、LLM に返します。
- 回答または継続：**LLM は結果に基づいて回答を生成するか、追加の情報が必要だと判断して再びツールを呼び出します。

モデルがツールを呼び出すかどうか、またどの引数を指定するかは、主にツールの用途とパラメーターの説明が明確かどうかによって左右されます。

主な用途

用途	例
リアルタイム情報や社内データの取得	注文状況、在庫、為替レート、社内システムの記録の確認
操作の実行	チケットの作成、予約、通知の送信

用途	例
複数ステップのタスク	顧客情報を調べ、その結果に基づいて契約を照会し、最後に回答をまとめます
自然言語から構造化クエリへの変換	Text to SQL。Text to SQL を参照してください

MaiAgent での動作

有効化の条件

Agent の **回答モード** は **Agent モード** である必要があります。**RAG Q&A** など、ほかの回答モードではツールを呼び出しません。

管理画面では、ツール呼び出しに対応するモデルにのみ Agent モードが提供されます。組織のプランによって、利用可能な回答モードが制限される場合もあります。

モデルが呼び出せるツール

提供元	説明	仕様
API ツール	1つのツールが1つの HTTP エンドポイントとメソッドに対応し、プラットフォームが代わりにリクエストを送信します	API ツールエンジニアリングガイド
MCP ツール	1つのツールが1つの MCP サーバーに対応し、そのサーバー上の「許可されたツール」がすべてモデルから呼び出せるツールになります	セルフホスト MCP Server 接続仕様 、 Remote MCP サービス概要
プラットフォーム内蔵ツール	ナレッジベース検索、Code Interpreter、Browser Tool などです。Agent の設定に応じて有効になります	ユーザーマニュアルを参照してください
スキル	スキルを紐付けると、モデルが <code>skill_expand_tool</code> を使ってスキルの指示と追加ツールを展開します	Skill スキルモジュール

Agent は自身に紐付けられたツールのみを呼び出せます。管理画面でツールを作成する際に選択できる種類は、API ツールと MCP ツールです。

ツール定義をモデルに渡す方法


名前：ツール名は英数字とアンダースコアに正規化され、最大 64 文字です。規則は [API ツールエンジニアリングガイド：ツール定義の対応関係](#) を参照してください。

用途の説明：API ツールでは「**プロンプト**」に値があればそれを使い、なければ「**説明**」を使います。MCP ツールでは、サーバーの `tools/list` が返す `description` を使います。

パラメーター構造：API ツールでは「**パラメーター構造 (JSON Schema)**」、MCP ツールではサーバーが返す `inputSchema` を使います。

ツール検索：Agent の「**ツール検索機能を有効化**」（デフォルトで有効）がオンの場合、大部分のツールの完全な定義は最初からモデルに渡されません。モデルはまず `tool_searching_tool` の説明で利用可能なツール名を確認し、呼び出す際に名前を検索して定義を読み込みます。紐付けられたツールが多い場合、モデルに毎回送信するツール定義を減らせます。

実行と結果の返却



引数の検証：モデルが指定した引数は、パラメーター構造に基づいて検証されます。引数が不適切な場合やツールの実行中にエラーが発生した場合、エラー内容がツールの結果としてモデルに返されます。モデルは引数を修正して再試行するか、ユーザーに説明するため、回答全体は中断されません。

複数のツール：モデルが同じステップで複数のツールを要求すると、プラットフォームは同時に実行します。

結果の長さ：ツールの結果がモデルのコンテキストウィンドウの一定割合（プラットフォームのデフォルトは 0.8）を超えると、先頭と末尾を残して中間を省略します。Agent では「**ツール結果の切り詰め**」も有効にでき、文字数の上限（デフォルトは 8000）で大きすぎる結果を切り詰めます。

繰り返し呼び出し：同じ回答内で、まったく同じ引数で同じツールを再び呼び出し、結果も同じだった場合、プラットフォームは同じ結果を返しません。代わりに、再試行しても異なるデータは得られない旨をモデルに伝えます。

実行記録：呼び出しごとに、入力引数、出力またはエラー、ステータス、所要時間を含むツール実行記録が保存されます。

Credits：API ツール、MCP ツール、および一部の内蔵ツールでは、呼び出しごとに Credits が消費されます。残高が不足している場合、その呼び出しは送信されず、モデルに残高不足の説明が返されます。

実行上限

設定	範囲とデフォルト	上限に達した場合
最大反復回数	1-100、デフォルトは 20 です。ツール呼び出しのラウンド数を数えます。ツール検索は含みません	Agent がツール呼び出しを停止し、まとめの回答を生成します
実行タイムアウト (秒)	30-1200、デフォルトは 600 です	ワークフローが終了し、タイムアウトメッセージが表示されます (カスタマイズ可能です)

先に達した上限が適用されます。反復回数を増やす際は、タイムアウト時間も増やしてください。そうしないと、先にタイムアウトしやすくなります。

制限と注意事項

モデルがツールを呼び出さない、または誤ったツールを呼び出す場合があります：プラットフォームは、モデルが適切なタイミングで適切なツールを呼び出すことを保証しません。モデルがツールを呼び出さなければ、ツール実行記録は作成されません。この場合、調整すべきものはツール自体ではなく、ツールとパラメーターの説明です。

ツールの説明が品質を左右します：各パラメーターに説明と形式の例を記載し、ツールの説明には用途、使用するタイミング、返却内容を明確に記載してください。

書き込み操作は再送に対応できる必要があります：API ツールはタイムアウトや一部のエラーで自動再試行し、モデルも繰り返し呼び出す場合があります。注文やチケット作成などの書き込み操作では、ツール側で幂等性を確保してください。詳細は [API ツールエンジニアリングガイド：タイムアウト、再試行、TLS](#) を参照してください。

キーをパラメーター構造に含めないでください：モデルはパラメーター構造と引数の値を参照できます。キーはツールのヘッダーや Query パラメーターに設定するか、連絡先の認証情報を使用してください。

一般的に、ツール呼び出し能力はモデルによって異なります：同じツールでもモデルを変更すると、呼び出すタイミングや引数の品質が変わる場合があります。モデルを変更したら再度テストしてください。

操作方法はユーザーマニュアルを参照してください

ツール機能の概要

API ツールの作成

MCP ツールの作成

Agent へのツール設定

回答の長さ と Agent の実行上限

ツール実行記録

Skill スキルモジュール


Skill とは？

Skill（スキル）は、タスクの指示、追加ツール、リソースファイルを、Agent が必要に応じて展開できる機能単位にまとめたものです。概念、利用場面、管理画面での操作については、ユーザーマニュアルの[スキル](#)をご覧ください。このページでは、動作原理、`SKILL.md` の仕様、API を説明します。

スキル（Skill） = 指示（Instructions） + ツール（Tools） + リソース（Resources）

Skill の動作原理

動作フロー



1. スキル一覧

Agent にスキルを関連付けると、モデルは最初に各スキルの名前と使用場面だけを参照します。使用場面には `SKILL.md` の `when_to_use` を使い、未設定の場合は `description` を使います。指示全文は、あらかじめコンテキストに読み込まれません。

2. スキルの展開 (Skill Expansion)

モデルが特定のスキルで質問を処理すべきだと判断すると、`skill_expand_tool` を呼び出します。

入力：スキル名 (`skill_name`、大文字・小文字を区別しません)

出力：スキルの指示全文 (`instructions`)、使用場面、追加ツール名 (`attached_tools`)、リソースファイル一覧とディレクトリ (`resource_files`、`resource_directory`) を含む JSON です

```
{
  "name": "skill_expand_tool",
  "arguments": {
    "skill_name": "休暇日数計算"
  }
}
```

3. 追加ツールとリソースファイル

追加ツール：スキルに関連付けられた API ツールと MCP ツールは、会話開始時にスキルとともに接続されます。モデルはスキルを展開した後、追加の読み込みなしで直接呼び出せます。

リソースファイル：Agent で Code Interpreter を有効にしている場合、スキルを展開するとリソースファイルがサンドボックスの `/workspace/skills/<スキル名>`

ディレクトリに読み込まれ、モデルがプログラムで参照できます。Code Interpreter が無効な場合、モデルは指示内容だけを取得します。

SKILL.md の仕様

スキルの中心となる定義ファイル `SKILL.md` は、YAML Frontmatter と Markdown 本文で構成されます。

```
---
name: スキル名
description: スキルの説明 (AI がこのスキルを起動するタイミングを決定)
---
```

スキルのタイトル

トリガー条件

ユーザーが XXX に関する質問をしたときに起動します。

実行手順

Step 1: 情報の確認

必要な情報をユーザーに提供してもらいます ...

Step 2: 情報の検索

retrieve_text_nodes を使ってナレッジベースを検索します ...

Step 3: 回答の生成

以下の形式で回答します：

- ① 適用法令
- ② 計算結果
- ③ 参考例

Frontmatter のフィールド

フィールド	必須	説明
<code>name</code>	はい	スキル名です。組織内で重複できません
<code>description</code>	はい	スキルの説明です。 <code>when_to_use</code> が未設定の場合、LLM はこの説明で起動するタイミングを判断します
<code>when_to_use</code>	いいえ	使用場面です。LLM はスキルを起動するかどうかを判断する際にこのフィールドを優先します

指示内容の作成に関する推奨事項

トリガー条件を明確にします：説明と指示に、適用場面と「適用しない」場면을明記します。

手順を構造化します：番号付きの手順（Step 1、Step 2...）を使い、LLM が順に実行できるようにします。

ツールの使用方法を示します：各手順で、使うツールと検索方針を明記します。

回答形式を定義します：テンプレートや表を使い、回答形式を統一します。

誤りを防ぐ確認項目を追加します：指示の末尾にチェックリストを加え、LLM が自分の出力を検証できるようにします。

スキルパッケージ (Skill Package)

ファイル構成

アップロードする `.skill` または `.zip` ファイルには、次の構成を含めます。

```
my-skill.skill (ZIP 形式)
├── # 必須：スキル定義
├── reference.pdf      # 任意：参考資料
├── template.xlsx     # 任意：テンプレートファイル
├── examples/         # 任意：サンプルディレクトリ
│   └── case1.json
```

セキュリティ検証

システムはスキルパッケージの解析時に、次のセキュリティチェックを行います。

圧縮率チェック：ZIP 爆弾攻撃を防ぐため、最大 100:1 に制限します

パストラバーサル対策： `../` などのパスインジェクションを防ぎます

ファイルサイズ制限：組織のアップロード制限に従います（デフォルトは 100 MB）

の検証：ファイルが存在し、有効な `name` と `description` を含む必要があります

API エンドポイント

スキルの CRUD

メソッド	エンドポイント	説明
GET	/api/v1/skills/	組織内のスキルを一覧表示します（ページネーションと検索に対応）
POST	/api/v1/skills/	スキルを手動で作成します
GET	/api/v1/skills/{id}	スキルの詳細を取得します
PATCH	/api/v1/skills/{id}	スキルを更新します
DELETE	/api/v1/skills/{id}	スキルを削除します（S3 のクリーンアップを含む）

スキルパッケージの操作

メソッド	エンドポイント	説明
POST	/api/v1/skills/upload/	.skill .zip をアップロードしてスキルを作成します
POST	/api/v1/skills/{id}/reupload/	再アップロードでスキルパッケージを置き換えます
GET	/api/v1/skills/{id}/export/	スキルを .skill ファイルとしてエクスポートします
GET	/api/v1/skills/{id}/package-structure/	スキルパッケージのファイル構成を確認します

リソース管理（ネストされたルート）

メソッド	エンドポイント	説明
GET	/api/v1/skills/{id}/resources/	スキルのリソースファイルを一覧表示します
POST	/api/v1/skills/{id}/resources/	リソースファイルをアップロードします
DELETE	/api/v1/skills/{id}/resources/{rid}	リソースファイルを削除します
GET	/api/v1/skills/{id}/resources/{rid}/download/	リソースファイルをダウンロードします

手動作成時のリクエストフィールド

POST /api/v1/skills/ は JSON でスキルを作成します（ Authorization: Api-Key <キー> 、 Content-Type: application/json ）。フィールド名は camelCase と snake_case の両方に対応し、レスポンスは常に camelCase です。

フィールド	必須	説明
name	はい	スキル名です。組織内で重複できず、フォルダー名に使える文字のみ使用できます
description	はい	スキルの説明です。 whenToUse が未設定の場合、モデルはこの説明で起動するタイミングを判断します
whenToUse	いいえ	使用場面です。モデルはスキルを起動するかどうかを判断する際にこのフィールドを優先します
instructions	はい	の内容（Markdown）です
attachedToolIds	いいえ	追加するツールの ID 配列です。有効なツールだけを受け付けます。レスポンスではこのフィールドを返さず、代わりに attachedTools でツールの概要を返します

フィールド	必須	説明
<code>groups</code>	ユーザーの立場によります	<code>[{"id": "<ロール ID>"}]</code> です。組織の owner は省略できますが、その他のメンバーは自分が所属するロールを少なくとも 1 つ指定する必要があります。未指定の場合は <code>400</code> を返します
<code>files</code>	いいえ	スキルに付属するリソースファイルです。各項目は <code>{"path": "scripts/run.py", "content": "...", "contentEncoding": "text" または "base64"}</code> です

成功時は `201` を返し、内容はスキルオブジェクトです（`id`、`createdAt`、`resources` を含む）。名前の重複、無効なツール ID、ロールの条件違反の場合は `400` を返し、内容はフィールドのエラーまたは `{"detail": "..."}` です。更新には `PATCH /api/v1/skills/{id}` を使い、フィールドは同じです（`files` を除く）。`name`、`description`、`whenToUse`、`instructions` のいずれかを変更すると、 が再生成されます。

スキル作成の例

手動作成：

```
POST /api/v1/skills/
{
  "name": "返品処理フロー",
  "description": "顧客の返品・交換依頼を処理します：注文の確認、返品条件の確認、返品依頼の作成。",
  "whenToUse": "顧客が返品、交換、返金に言及したときに起動します",
  "instructions": "# 返品処理\n\n## Step 1：情報の確認\n...",
  "attachedToolIds": [
    "uuid-of-order-query-tool",
    "uuid-of-return-api-tool"
  ]
}
```

スキルパッケージのアップロード：

```
curl -X POST /api/v1/skills/upload/
-F "file=@my-skill.skill"
-F "attached_tool_ids=["uuid-1","uuid-2"]"
```


スキルと Agent の関連付け

スキルと Agent は、`ChatbotSkill` 中間モデルを介して多対多で関連付けられます。

1 つの Agent に複数のスキルを関連付けられます

1 つのスキルを複数の Agent が使用できます

関連付けと解除の操作は `ChatbotSkillEvent` 履歴テーブルに記録されます



設計上の特性と制限

指示とツールを分けて管理します

スキルには指示内容、使用場面、リソースファイルを保存します。追加ツールは組織の既存ツールへの参照です。スキルの指示を変更してもツール設定は変わりません。ツール自体（URL、ヘッダーなど）を変更すると、そのツールを追加しているすべてのスキルと、それらのスキルに関連付けられた Agent に影響します。

必要に応じた展開

スキルの指示全文は、モデルが `skill_expand_tool` を呼び出した時点でコンテキストに入ります。展開前のスキルが占めるのは名前と使用場面だけです。[スキル一覧](#)をご覧ください。そのため、スキルが使われるかどうかは、モデルが使用場面から適用を判断できるかに依存します。使用場面が曖昧だと、スキルが展開されない場合があります。よくある表現と「適用しない」場면을記載することをおすすめします。

エクスポートと組織間インポート

エクスポートした `.skill` ファイルには、`usecase` とすべてのリソースファイルが含まれます。手動作成したスキルでは、生成された `usecase` に使用場面と追加ツール名も含まれます。

別の組織にアップロードすると、システムはツール名を使って、その組織のツールに再度関連付けます。一致するツールが見つからない項目（ツール名がない MCP ツールを含む）はアップロード結果に表示され、手動での関連付けが必要です。

ツール本体とその認証情報は、スキルパッケージに含めてエクスポートされません。

再アップロード

アップロードで作成したスキルは、再アップロード（Reupload）できます。新しいスキルパッケージで名前、説明、指示内容、すべてのリソースファイルを置き換え、古いリソースファイルは削除されます。プラットフォームは旧版のスキルパッケージを保持しません。復元が必要な場合は、以前の `.skill` ファイルを自身で保存してください。手動作成したスキルは再アップロードできません。

権限管理

スキルページへのアクセスは「**スキル権限**」(`chatbot_skill_access`) で制御します。組織が作成したスキルはロールに割り当てられ、「ロール × スキル」の各組み合わせで読み取り・編集・削除を個別に設定できます。ロールには「**スキルの新規作成を許可**」の切り替えもあります。設定方法は、ユーザーマニュアルの[ロールごとのスキル表示と権限の管理](#)をご覧ください。

操作方法はユーザーマニュアルをご覧ください

スキル：概念と利用場面

スキル管理：作成、アップロード、ツールの追加、エクスポート、Agent への関連付け

Canvas

Canvas とは

一般に Canvas（キャンバス）は、会話の横に「完成した 1 つの出力」を独立して表示するインターフェースです。ドキュメント、図、Web ページ、インタラクティブなコンポーネントを会話のテキストと分け、個別にプレビュー、繰り返しの修正、ダウンロードができます。

MaiAgent では、Canvas は Agent モード内の設定の一つです。Agent が今回の出力はキャンバスに適していると判断すると、プラットフォーム内蔵のキャンバスエージェントにコンテンツの生成を引き継ぎます。会話インターフェースはコンテンツの種類に応じてレンダリングします。


MaiAgent での仕組み

設定と有効化

Agent：Agent の **回答モード設定** で **回答モード** を **Agent モード** に設定し、その下の **Agent モード** で **キャンバスモード (Canvas)** を選択します。ツール呼び出しに対応したモデルのみキャンバスモードを選択できます。組織のプランによって、利用可能な Agent モードが制限される場合もあります。

MaiGPT：デフォルトでキャンバスモードを使用し、メンバーは会話内で直接利用できます。

1 回の回答の流れ



引き継ぎ：キャンバスモードの Agent には引き継ぎツールが追加され、システムプロンプトにも引き継ぎの説明が含まれます。図の作成、データの可視化、Web ページや UI コンポーネントの作成、書式付きドキュメン

トの生成では、キャンバスエージェントに引き継ぎます。地図は例外で、Agent が場所検索ツールで座標を取得済みの場合は、プロンプトに従って自身で地図キャンバスを出力します。

生成：キャンバスエージェントは Agent と同じモデルを使い、プラットフォームに設定されたキャンバスプロンプトに従ってコンテンツを生成します。このターンでナレッジベースから取得した情報も、そのプロンプトに含まれます。ツール呼び出しの反復回数も、Agent の「最大反復回数」の制限を受けます。

マーカー：各キャンバスには `name`（識別名。同じ名前を使うと同じキャンバスを更新します）、`type`（コンテンツの種類）、`title`（タイトル）、`display`（表示位置）が付いています。

保存：プラットフォームはキャンバス内容を会話とともに保存するため、会話を再度開いたときにも閲覧できます。

対応するコンテンツの種類

<code>type</code>	表示方法	ダウンロード形式
<code>markdown</code>	Markdown ドキュメントです	<code>.md</code>
<code>html</code>	HTML、CSS、JS を 1 ファイルに記述した HTML ページを iframe 内で実行します	<code>.html</code>
<code>svg</code>	ベクター画像です	<code>.svg</code>
<code>mermaid</code>	フローチャート、シーケンス図、ガントチャートなどです。コンテンツのストリーミング完了後に描画します	<code>.md</code> （他の会話プラットフォームのダウンロードリンクでは <code>.mmd</code> です）
<code>react</code>	ブラウザ側でコンパイルしてプレビューする React コンポーネントです。React、lucide-react、recharts、shadcn/ui コンポーネント、Tailwind クラスを使用できます	<code>.jsx</code>
<code>map</code>	中心点、場所のマーカー、経路を含む JSON によるインタラクティブな地図です	<code>.json</code>

キャンバスパネルでは、プレビュー、ソースコードの表示、元の形式または PDF でのダウンロードができます。

表示位置

<code>display</code>	用途
<code>inline</code>	会話メッセージに直接埋め込み、現在の内容の理解を助ける小さな図表や説明図に使用します
<code>panel</code> （デフォルト）	サイドパネルで開き、保存、修正、会話外での使用を想定する出力に使用します。ドキュメント、完全な Web ページ、インタラクティブなコンポーネント、地図などが該当します。長いコンテンツ（およそ 40 行を超える場合）にもパネルを使用します

キャンバスは Web Chat と MaiGPT Web 版の会話インターフェースでのみレンダリングされます。LINE、Microsoft Teams、Slack などの他の会話プラットフォームでは表示できません。プラットフォームは回答の後にキャンバスのダウンロードリンクを追加し、リンクは 7 日間有効です。

キャンバスを使用する場面

キャンバスエージェントへの引き継ぎ条件とプロンプトの規則は次のとおりです。

引き継ぐ場合：ユーザーが図の作成（例：SVG）、データや概念の可視化（例：Mermaid）、Web ページや UI コンポーネントの作成、書式付きドキュメントやレポートの生成、地図上での場所の表示を求めた場合です。

キャンバスを使わない傾向がある場合：解説やチュートリアル、既存の内容への提案、現在の会話に依存する内容、単発の質問です。会話内に直接表示できる場合、プロンプトは会話内での提示を指示します。

1 メッセージにつき 1 キャンバス：ユーザーが求めない限り、各回答では 1 つのキャンバスのみ生成します。

キャンバスを使いたい場合は、質問時に「キャンバスで……を作成してください」などと明示してください。

地図キャンバス

デプロイ環境に Google Maps API キーが設定されている場合のみ、キャンバスエージェントは場所検索（`place_search`）と公共交通機関の経路検索（`get_transit_directions`）の 2 つのツールを利用できます。これらのツールがない場合、モデルの既存の知識に基づいて有名な場所を表示することしかできません。この 2 つのツールは、呼び出すたびに Credits を消費します。MaiGPT メンバーのロールで対応する公式ツールが許可されていない場合、キャンバスエージェントにも提供されません。

主な活用例

活用例	よく使う種類
フローチャート、組織図、シーケンス図、ガントチャートです	<code>mermaid</code>
レポート、Email、議事録などのドキュメントです	<code>markdown</code>
ナレッジベースやデータベースから取得したデータによるグラフやダッシュボードです	<code>react</code>
単一ページの Web サイトやインターフェースのプロトタイプです	<code>html</code> 、 <code>react</code>
場所の紹介、旅行計画、交通経路です	<code>map</code>
簡単なアイコンや説明図です	<code>svg</code>

データベースのクエリ結果からレポートを作成する方法は、ユーザーマニュアルの [Text to SQL レポート作成 \(Canvas モード\)](#) をご覧ください。

デモ動画

 預覽連結：https://drive.google.com/file/d/1GW7o3m130M-yESZ4h6VwZvNXDhdJDdFe/view?usp=drive_link

制約と注意事項

ロール指示はキャンバスエージェントに渡されません：キャンバスエージェントのシステムプロンプトは、プラットフォームに設定されたキャンバスプロンプトと、このターンのナレッジベース情報で構成され、Agent のロール指示は含まれません。会話全体は参照できますが、ロール指示にある書式、用語、ブランドに関する要件がキャンバス内容に反映されるとは限りません。必要な場合は質問内で直接指定してください。

キャンバスプロンプトはプラットフォーム単位の設定です：すべての組織が同じキャンバスプロンプトを共有し、組織側で独自に調整することはできません。

HTML と React の制約：Web Chat の HTML キャンバスはサンドボックス化された iframe 内で実行されます。スクリプトの実行のみが許可され、ホスト Web サイトとは異なるオリジンのため、ホスト Web サイトの Cookie やストレージにはアクセスできません。キャンバスプロンプトはモデルに対し、Web 上の画像を使わず、外部スクリプトを `cdnjs.cloudflare.com` からのみ読み込むよう指示します。React キャンバスで import できるのは、上の表に記載されたパッケージのみです。

正しくレンダリングされる保証はありません：プラットフォームは生成後にキャンバス内容の構文を検査しません。モデルが生成したコードや図の構文に誤りがあると、表示できない場合があります。Agent に修正と再生成を依頼できます。

修正方法：Markdown キャンバスは画面上で直接編集できません。修正する場合は、会話で変更箇所を説明してください。キャンバスプロンプトは、同じ `name` で内容全体を再生成するよう指示します。または、ソースファイルをダウンロードして編集できますが、ローカルでの変更はキャンバスに反映されません。

他の会話プラットフォームにはダウンロードリンクのみ提供されます：上の表示位置をご覧ください。

操作方法はユーザーマニュアルをご覧ください

MaiGPT の Canvas キャンバス：キャンバスの閲覧、ダウンロード、AI への修正依頼を説明します

Agent のツール設定：Agent の回答モードの切り替え

Text to SQL レポート作成（Canvas モード）

AI 安全保護機構

MaiAgent は、コンテンツが大規模言語モデルに出入りする経路上で、複数の保護機能を提供します。これらはシステムによって強制的に実行され、モデルの「自制」に依存しません。このページでは、各機能を誰が設定するか、どこで作用するか、どのような場面に適しているかを説明します。管理画面での操作手順はユーザーマニュアルを参照してください。

機能の概要

機能	設定できる人	適用箇所	適した場面
Hook メッセージインターセプト	「Hook 権限」を持つメンバーが管理画面で設定します	コンテンツをモデルに送信する前、AI の回答を送信する前	個人情報のマスキング、プロンプトインジェクションや不適切なコンテンツの遮断、機密語句の検出、回答のチェック
ICAP コンテンツ検証	MaiAgent が組織の要件に応じて設定します	会話メッセージと添付ファイル、ナレッジベースのファイル（範囲は該当ページを参照してください）	既存の ICAP ウイルス対策／DLP サービスを持ち、既存のセキュリティ管理に組み込む必要がある企業
AWS Bedrock Guardrails	MaiAgent のみが Agent に設定できます	ユーザー入力、AI の回答	Bedrock Guardrails のポリシー（コンテンツフィルタリング、拒否するトピック、個人情報のマスキング、根拠のチェック）が必要な場面

この3つの機能は、それぞれ個別に設定・実行されます。共通のポリシー層や、統一された「遮断／警告／許可」のルール表はありません。Hook はコンテンツを書き換えたり遮断したりし、Bedrock Guardrails は自身のポリシーに従って遮断またはマスキングし、ICAP はスキャン結果に応じてファイルを許可または拒否します。複数の機能を有効にしている場合、コンテンツはそれぞれのチェックを通過します。いずれかの機能が遮断した場合、モデルやユーザーには送信されません。また、プラットフォームはサードパーティーの実行時プロンプトインジェクション対策製品（WAF や AI ファイアウォールなど）を統合していません。このような制御が必要な場合は、ユーザーと MaiAgent の間のネットワーク層に配置するか、Hook のプロンプトインジェクション検出を使用してください。

システムプロンプトはセキュリティ制御ではありません。システムプロンプトは Agent の口調や回答範囲を導くことができますが、モデルに送信するテキストにすぎません。モデルが誘導されて従わない場合があります、すでに検索された文章も遮断できません。特定のコンテンツが「確実に」モデルに入らない、または回答に現れないようにするには、このページの機能を使用してください。ユーザーが検索できる文書を制限するには、[Query Metadata](#) を使用してください。システムプロンプトの書き方は、ユーザーマニュアルの [システムプロンプト設計ガイド](#) を参照してください。

Hook メッセージインターセプト

Hook は顧客が自分で設定できる保護層です。テンプレートから Hook を作成し、パラメーターを調整してから Agent に適用します。1 つの Agent に複数の Hook を適用でき、順番に実行されます。

利用条件：プラットフォームで Hook 機能が有効になっており、組織に Hook の利用権がある必要があります（エンタープライズプランには自動的に付与されるほか、MaiAgent が個別に有効化することもあります）。管理画面に Hook メニューが表示されない場合は、MaiAgent の担当者にお問い合わせください。

適用箇所と処置

タイミング	チェックするコンテンツ
コンテンツをモデルに送信する前	ユーザーメッセージ、添付ファイルの内容、ナレッジベースから検索された文章、Agent モードでのツールの返却結果
AI の回答を送信する前	Agent が生成した回答

処置には、**書き換え**（例えば、個人情報をマスキングしてから送信します）と **遮断**（そのコンテンツを遮断し、カスタムメッセージを返します）の 2 種類があります。添付ファイルの内容、ナレッジベースの文章、ツールの結果が遮断された場合、その部分だけがモデルに送信されず、会話は中断されません。

検出方法

方法	説明	データの送信先
ルール照合	Email、携帯電話番号、個人識別番号、クレジットカード番号、指定した禁止語句などを、形式やキーワードで照合します	MaiAgent プラットフォーム内で処理します
大規模言語モデルによる判定	選択したモデルを使い、プロンプトインジェクション攻撃かどうか、回答に根拠が欠けているかなどを判定します	選択したモデルに送信します
個人情報検出サービス	名前や住所など、固定形式のない個人情報を検出します。現在は Google Cloud DLP を提供しています	検出サービスに送信します
コンテンツ安全性分類サービス	ヘイト、ハラスメント、性的コンテンツ、暴力、自傷、違法行為、脱獄攻撃などのカテゴリで判定します。現在は OpenAI Moderation を提供しています	分類サービスに送信します

個人情報検出とコンテンツ安全性分類では、スキャンした文字数に応じてクレジットが消費されます（1,000 文字単位）。利用可能なテンプレート、各テンプレートのパラメーター、各インターセプトの記録については、ユーザーマニュアルの [Hook メッセージインターセプト](#)、[Hook の追加と設定](#)、[Hook 実行記録](#) を参照してください。

AWS Bedrock Guardrails

AWS Bedrock Guardrails は AWS が提供する保護サービスです。MaiAgent は個別の Agent に Guardrail (ID とバージョン) を指定できます。その後、その Agent の会話は指定された Guardrail のチェックを受けます。

ユーザー入力：モデルに送信する前にチェックします。遮断ルールに該当すると、Guardrail に設定された遮断メッセージを直接返します。

AI の回答：送信する前に、質問や検索された文章とあわせてチェックします。遮断ルールに該当すると遮断メッセージに置き換え、マスキングルールに該当するとマスキング後の内容を返します。

利用上の制限：

MaiAgent のみが設定できます：管理画面には設定項目がありません。Guardrail は、MaiAgent プラットフォームが呼び出す AWS 環境に作成する必要があります。顧客自身の AWS アカウントに作成した Guardrail は直接適用できません。必要な場合は MaiAgent の担当者にお問い合わせください。

回答は逐次ストリーミングされません：Guardrail を適用した Agent は、チェック完了後に回答全体を一度に送信します。

AWS Bedrock に接続できる必要があります。オフラインのオンプレミス環境では利用できません。

AWS が不要な場合は、自分で設定できる [Hook](#) を優先して使用することをお勧めします。

OAuth 2.0 連携と Token 自動更新機構

本ドキュメントでは、MaiAgent プラットフォームが OAuth 2.0 認証プロトコルと連携し、トークンを自動更新することで、外部サービスとの連携の安全性と継続的な利用を確保する仕組みを説明します。

1. OAuth 連携が必要な理由

MaiAgent はエンタープライズ向け Agent プラットフォームとして、Google Workspace、Salesforce、GitHub など、さまざまな外部サービスとの密接な連携を必要とします。OAuth 2.0 は標準化された安全な認可の仕組みを提供し、以下の主要な課題を解決します。

検討事項	従来のパスワード保存方式	OAuth 2.0 認可方式
セキュリティ	ユーザーのアカウントとパスワードを保存する必要があり、漏えいのリスクがあります	ユーザーのパスワードを保存せず、有効期間の短いアクセストークンを使用します
権限制御	通常はアカウントの全権限を使用し、細かく分けられません	Gmail の読み取りのみ、カレンダーの管理のみなど、認可スコープ (Scope) を細かく制御できます
取り消しの仕組み	アクセスを取り消すにはパスワードの変更が必要です	他のサービスに影響を与えず、特定のアプリケーションのアクセス権をいつでも取り消せます
ユーザー体験	外部プラットフォームでパスワードを入力する必要があります	信頼できるサービス本来の画面で認可を完了でき、よりスムーズに利用できます

一般的な利用例は以下のとおりです。

- ツールコネクタ (Tool Connector)** : Agent が OAuth 認可を通じて Google Drive、Notion、Slack などにアクセスし、ファイルの読み取りやメッセージ送信などの操作を行います
- データ同期** : Salesforce などの CRM システムから顧客データを自動同期し、手動インポートを不要にします
- ワークフローの自動化** : Jira、Asana などのプロジェクト管理ツールと連携し、Agent がタスク作成やステータス更新を支援します

2. MaiAgent の OAuth 連携アーキテクチャ



Mermaid 圖表

2.1 認可フローの最適化

MaiAgent は以下の主要な最適化を実装しています。

状態検証 (State Validation)：認可リクエストごとに一意の state パラメータを生成し、CSRF 攻撃を防ぎます

メンバー単位の認可：組織メンバーが個別に OAuth 認可を行えるため、より細かな権限管理が可能です

柔軟なコールバック処理：connector_id パラメータを任意とし、組織単位とメンバー単位の認可モードに対応します

Access Token の検証：トークンレスポンスに access_token が存在することを必須検証し、認可フローの完全性を確保します

2.2 トークンの安全な保存

MaiAgent は複数のセキュリティ対策で OAuth トークンを保護します。

暗号化保存：すべてのトークン (Access Token、Refresh Token) を保存前に暗号化します

クライアント認証情報の管理：OAuth アプリケーションの client_id と client_secret を保存し、トークン更新に使用します

トークンのメタデータ：トークンの有効期限、認可スコープ、関連するユーザーとコネクタの情報を記録します

旧形式のトークンの処理：クライアント認証情報のない旧形式のトークンを自動的に除外し、自動更新できるトークンのみを使用します

2.3 トークンの自動更新の仕組み

アクセストークン (Access Token) の有効期間は通常短く設定されています。MaiAgent は期限切れになる前に、**定期更新**と**使用時更新**の2つの方法で新しいトークンを取得するため、Agent やコネクタが毎回ユーザーに再認可を求める必要はありません。

```
sequenceDiagram
    participant Scheduler as スケジュールタスク
    participant DB as トークンデータベース
    participant OAuth as OAuth プロバイダー
    loop 20 分ごと
        Scheduler->>DB: 期限切れ、または 30 分以内に期限切れになる、
        直近 7 日間に活動があったトークンを検索（1 回につき最大 50 件）
        DB-->>Scheduler: 更新対象のトークン一覧
        loop 1 件ずつ処理
            Scheduler->>OAuth: Refresh Token を新しい Access Token と交換
            alt 更新成功
                OAuth-->>Scheduler: 新しいトークン情報
            Scheduler->>DB: トークンと有効期限を更新
            else 認可サーバーが 400／401 を返却
                Scheduler->>DB: この認可を無効化（再認可が必要）
            else その他のエラー
                Scheduler->>DB: 現状を維持し、次のスケジュール実行で再試行
            end
        end
    end
```

Mermaid 圖表

定期更新のルール

項目	ルール
実行頻度	20 分ごとに 1 回実行します
更新対象	期限切れ、または 30 分以内に期限切れになるトークンです
対象範囲	メンバーが認可したコネクタ、メンバーが認可した MCP ツール、および連絡先が認可したコネクタです
活動条件	メンバーのトークン：直近 7 日以内に更新され、メンバーと所属組織の両方が有効であること。連絡先のトークン：直近 7 日以内に使用されていること（未使用の場合は認可日時を基準にします）
必須条件	Refresh Token があり、OAuth Client ID が保存されていること。無効化されたコネクタやツールはスキップします
1 回の処理件数	最大 50 件を有効期限順に処理します。同時に実行される更新タスクは 1 つだけです
個別の更新失敗	エラーを記録し、同じ実行内では再試行しません。条件を満たしていれば、次のスケジュール実行で再試行します
タスク全体の実行失敗	固定間隔の 60 秒後に再試行し、最大 3 回まで試みます
認可サーバーによる拒否（HTTP 400／401）	この認可を無効化し、ユーザーは再認可する必要があります
レスポンスに新しい Refresh Token がない場合	元の Refresh Token を引き続き使用します

7 日を超えて活動のないトークンは定期更新されません。メンバーが無効化された場合や組織を離れた場合も、そのメンバーのトークンは更新されなくなります。その後の使用時は、以下の「使用時更新」に従って処理します。Refresh Token が無効になっている場合は、再認可が必要です。

使用時更新

Agent がトークンを使用する際、期限切れまたは 60 秒以内に期限切れになる場合は、プラットフォームが先に新しいトークンを取得してから呼び出します。更新に失敗すると、その呼び出しではトークンを取得できません。コネクタの認可更新に失敗した場合は、再試行を一定時間停止します。停止時間は 60 秒から始まり、失敗するたびに倍増し、最大 1 時間になります。MCP ツールのトークン（メンバー認可または組織共用）も、使用前に同じ 60 秒のルールで更新します。

2.4 メンバー単位の認可対応

MaiAgent は、より細かなメンバー単位の OAuth 認可に対応しています。

独立した認可フロー：各組織メンバーが、組織管理者の介入なしに OAuth 認可を個別に完了できます

認可メタデータ：OAuth state にメンバー関連のコンテキスト情報を含め、認可フローを正確に追跡します

リダイレクト URI の簡素化：OAuth コールバック URI の構造を最適化し、連携の柔軟性と保守性を高めます

フロントエンドの状態管理：sessionStorage を使用してメンバーの OAuth リダイレクトを管理し、認可フローの連続性を確保します

3. OAuth 連携のベストプラクティス

3.1 認可スコープ（Scope）の設計原則

OAuth アプリケーションを設定する際は、最小権限の原則に従ってください。

必要な権限のみを要求：Google Calendar の読み取りだけが必要な場合は、Gmail の書き込み権限を要求しないでください

ユーザーへの明確な説明：認可前に、その権限が必要な理由を明確に説明してください

段階的な認可に対応：追加の権限が必要になった際に、ユーザーを再度認可フローへ案内してください

3.2 トークンのライフサイクル管理

MaiAgent のトークン管理は、以下のベストプラクティスに従っています。

Access Token：有効期間は短く（通常 1 時間）、実際の API 呼び出しに使用します

Refresh Token：有効期間は長く（数か月から無期限の場合もあります）、新しい Access Token の取得に使用します

自動更新のタイミング：20 分ごとに確認し、30 分以内に期限切れになるトークンを更新します。使用時も 60 秒以内に期限切れになる場合は先に更新します。ルールは [2.3](#) を参照してください

Refresh Token の無効化：認可サーバーが更新を拒否した場合、その認可を無効化し、ユーザーは再認可する必要があります

3.3 セキュリティ上の考慮事項

HTTPS の必須化：OAuth 関連の通信はすべて HTTPS を使用する必要があります

State パラメータの検証：CSRF 攻撃を防ぎ、認可リクエストの完全性を確保します

トークンの暗号化保存：業界標準の暗号化アルゴリズムで機密データを保護します

定期監査：すべてのトークン使用状況を記録し、セキュリティレビューに役立てます

4. MaiAgent の OAuth 連携の技術的な利点

4.1 開発・連携の利点

標準化されたインターフェース：OAuth 2.0 標準に従い、大多数の外部サービスと互換性があります

設定の簡素化：管理者が OAuth アプリケーションの基本情報を提供するだけで連携を完了できます

保守の自動化：トークン更新は完全に自動化され、手動の対応は不要です

柔軟なデプロイ：組織単位とメンバー単位の複数の認可モードに対応します

4.2 セキュリティ・コンプライアンスの利点

パスワードを保存しません：ユーザーのパスワード保存によるセキュリティリスクを完全に回避します

細かな権限制御：サービスごとに異なる認可スコープを設定できます

即時取り消し：管理者またはユーザーがいつでも認可を取り消せ、変更は即座に反映されます

監査証跡：すべての認可とトークン使用の活動を完全に記録します

4.3 ユーザー体験の利点

シームレスな更新：トークンの自動更新はユーザーに意識させず、利用体験に影響しません

スムーズな認可：信頼できるサービス本来の画面で認可を完了でき、パスワード漏えいを心配する必要がありません

継続的な利用：Refresh Token が有効である限り、サービスを継続して利用できます

5. 関連技術ドキュメント

[Remote MCP サービスの概要](#) - OAuth を通じた Remote MCP サービスとの連携方法を説明します

[Composio 連携](#) - Composio プラットフォームの OAuth 連携例を紹介します

[Zapier 連携](#) - Zapier プラットフォームの OAuth 連携ガイドです

参考リンク

[OAuth 2.0 RFC 6749](#)

[OAuth 2.0 Security Best Current Practice](#)

PKCE for OAuth Public Clients (RFC 7636).

ICAP コンテンツ検証連携

本ドキュメントでは、MaiAgent プラットフォームが ICAP (Internet Content Adaptation Protocol) を統合し、ユーザーがアップロードしたファイルと会話内容のセキュリティスキャンおよび検証を行い、マルウェアや不適切なコンテンツを防ぐ仕組みを説明します。

1. ICAP とは？

ICAP (Internet Content Adaptation Protocol) は、コンテンツを外部サービスに転送して、ウイルススキャン、コンテンツフィルタリング、情報漏えい防止などの処理を行う軽量なプロトコルです。

1.1 ICAP の主な価値

観点	コンテンツ検証なし	ICAP コンテンツ検証あり
セキュリティ	ユーザーがマルウェアや不適切なコンテンツをアップロードする可能性があります	悪意のあるファイルやコンテンツを自動でスキャンし、ブロックします
コンプライアンス	企業の情報セキュリティポリシーの要件を満たすことが困難です	エンタープライズ向けのウイルス対策および DLP ソリューションを統合します
柔軟性	コンテンツ検出ロジックを独自に開発する必要があります	標準プロトコルで専門的なサードパーティサービスを統合します
保守性	ウイルス定義と検出ルールを継続的に更新する必要があります	専門ベンダーが検出エンジンを保守します

1.2 主な利用シーン

ファイルアップロードの安全性: ナレッジベースにアップロードするドキュメントは、事前にウイルススキャンを行います

会話内容のフィルタリング: 会話に不適切な発言や機密情報が含まれていないか検出します

情報漏えい防止 (DLP): 機密情報を含むファイルのアップロードを防ぎます

コンプライアンスチェック: コンテンツが GDPR、HIPAA などの法規制の要件を満たしているか確認します

2. MaiAgent の ICAP 統合アーキテクチャ

```

flowchart TB
    subgraph Client["クライアント"]
        User["ユーザー"]
        WebChat["Web Chat インターフェース"]
    end
    subgraph MaiAgent["MaiAgent プラットフォーム"]
        API["Upload API"]
        Queue["処理キュー"]
        ICAP_Client["ICAP クライアント"]
        DB["データベース"]
        Storage["ファイルストレージ"]
    end
    subgraph ICAP_Service["ICAP サービス"]
        Scanner["ウイルス対策エンジン"]
        DLP["DLP エンジン"]
        Filter["コンテンツフィルター"]
    end
    User -- "ファイルをアップロード" --> WebChat
    WebChat -- "HTTP POST" --> API
    API --> Queue
    Queue --> ICAP_Client
    ICAP_Client --> ICAP_Client
    ICAP_Client -- "ICAP REQMOD" --> Scanner
    Scanner -- "ICAP RESPMOD" --> ICAP_Client
    ICAP_Client -- "ICAP OPTIONS" --> Filter
    Filter -- "検証成功" --> Storage
    ICAP_Client -- "結果を記録" --> DB
    ICAP_Client -- "検証失敗イベントを送信" --> WebChat
    WebChat -- "エラーを表示" --> User

```

Mermaid 図表

2.1 主要コンポーネントの説明

ICAP クライアント: MaiAgent に組み込まれた ICAP プロトコルの実装で、ICAP サーバーとの通信を担当します

ICAP サーバー: Symantec、McAfee、Trend Micro のウイルス対策ゲートウェイなど、サードパーティのコンテンツスキャンサービスです

処理キュー: ファイルのアップロードとスキャンタスクを非同期で処理し、ユーザー操作のブロックを防ぎます

スキャン記録: ファイルのハッシュ、スキャン時刻、結果など、すべてのスキャン結果を保存します

2.2 ICAP リクエストの流れ

```

sequenceDiagram
    participant User as ユーザー
    participant WebChat as Web Chat
    participant MaiAgent as MaiAgent
    participant API as Upload API
    participant ICAP as ICAP サーバー
    participant Storage as ファイルストレージ

    User->>WebChat: ファイルをアップロード
    WebChat->>MaiAgent: POST /upload
    MaiAgent->>MaiAgent: ファイル ID を生成
    Note over MaiAgent,ICAP: ICAP REQMOD リクエスト
    MaiAgent->>ICAP: REQMOD /scan HTTP/1.1
    Encapsulated: req-hdr=0, req-body=...
    ICAP->>ICAP: ファイルの内容をスキャン
    alt ファイルが安全
    ICAP-->>MaiAgent: 200 OK (ファイルの検証成功)
    MaiAgent->>Storage: ファイルを保存
    Storage-->>MaiAgent: 保存成功
    MaiAgent-->>WebChat: 200 OK {fileId: ...}
    WebChat-->>User: アップロード成功
    else ファイルに問題あり
    ICAP-->>MaiAgent: 403 Forbidden (ウイルス/ポリシー違反のコンテンツ)
    MaiAgent->>WebChat: Socket.IO: ICAP_BLOCKED イベント
    WebChat-->>User: エラーメッセージを表示
    MaiAgent->>MaiAgent: スキャン失敗を記録
    else ICAP サーバーエラー
    ICAP-->>MaiAgent: 500 Internal Server Error
    MaiAgent->>WebChat: Socket.IO: ICAP_ERROR イベント
    WebChat-->>User: システムエラー、しばらくしてから再試行してください
    MaiAgent->>MaiAgent: エラーログを記録
    end

```

Mermaid 図表

3. ICAP プロトコル実装の詳細

3.1 ICAP リクエストの形式

MaiAgent は REQMOD (Request Modification) モードでファイルを ICAP サーバーに送信します:

```
REQMOD icap://icap-server.example.com/scan ICAP/1.0
```

```
POST /upload HTTP/1.1
```

```
400
[Binary file content in chunked encoding]
0
```

主要フィールドの説明:

REQMOD: リクエスト変更モードです。コンテンツを保存する前に検査します

Encapsulated: HTTP リクエストのカプセル化形式を記述します

Allow: 204: コンテンツの変更が不要な場合、ICAP サーバーがそのまま 204 を返せることを伝えます

Chunked Encoding: チャンク転送エンコーディングでファイルの内容を送信します

3.2 チャンク転送エンコーディング (Chunked Transfer Encoding)

MaiAgent は HTTP チャンク転送エンコーディングを正しく実装しています:

```
チャンク転送形式:
<データサイズ (16進数) >\r\n
<データ内容>\r\n
...
0\r\n\r\n (終了マーカー)
```

正しいチャンクエンコーディングが必要な理由

ICAP プロトコルでは、リクエストとレスポンスのボディの送信に HTTP チャンク転送エンコーディングが必要です

エンコーディング形式が正しくないと、ICAP サーバーはファイルの内容を正しく解析できません

MaiAgent はチャンクサイズの16進数表記を修正し、ICAP 標準との互換性を確保しました

3.3 ICAP レスポンスの処理

ICAP サーバーは次のレスポンスを返す場合があります:

ステータスコード	意味	MaiAgent の処理
200 OK	コンテンツを検査または変更しました	変更後のコンテンツ（変更がある場合）を受け入れ、ファイルを保存します
204 No Content	コンテンツの変更は不要です	元のファイルをそのまま保存します
403 Forbidden	コンテンツは禁止されています（ウイルスを含む場合など）	保存を拒否し、クライアントに ICAP_BLOCKED イベントを送信します
500 Internal Error	ICAP サーバーエラーです	エラーを記録し、クライアントに ICAP_ERROR イベントを送信します

4. WebChat との統合

ICAP スキャンが完了すると、システムはスキャン結果をリアルタイムでユーザーに通知します:

ファイルのブロック: わかりやすいエラーメッセージを表示し、ファイルが拒否された理由（ウイルスの検出など）を説明します

システムエラー: ユーザーにしばらくしてから再試行するよう案内し、エラーログを記録します

ユーザー体験の改善

即時フィードバック: ファイルのアップロード直後に「スキャン中」の状態を表示します

進行状況の表示: 大きなファイルのアップロード時にプログレスバーを表示します

わかりやすいエラーメッセージ: ファイルが拒否された理由を平易な言葉で説明します

再試行の仕組み: 一時的なエラーの場合、再アップロードの選択肢を提供します

5. スキャン記録の管理

5.1 記録の保存

MaiAgent はすべての ICAP スキャンの詳細な記録を保存します:

各スキャン記録には次の情報が含まれます:

フィールド	説明
ファイル識別子	スキャンしたファイルの一意の識別子です
ファイル名	元のファイル名です
ファイルハッシュ値	ファイルの整合性を確認するための SHA-256 ハッシュです
スキャン結果	PASS（合格）、BLOCKED（ブロック）、ERROR（エラー）です
スキャン理由	ファイルがブロックされた場合の具体的な理由を記録します
ICAP サーバー	スキャンを実行した ICAP サーバーのアドレスです
スキャン時刻	スキャン実行時のタイムスタンプです
ユーザー 組織	スキャンを開始したユーザーと所属組織です

5.2 期限切れ記録の削除

MaiAgent は期限切れのスキャン記録を定期的に削除する自動クリーンアップ機能を実装しています:

システムはバックグラウンドのスケジュールタスクを通じて、保存期間を超えたスキャン記録を自動で削除します。

クリーンアップ方針:

保存期間: 組織の ICAP 設定の「記録保存日数」に従います。デフォルトは30日で、0を指定すると永久保存になります

適用範囲: 保存日数は組織単位で設定し、同じ組織のすべてのスキャン記録に同一の期間を適用します

6. 設定とデプロイ

6.1 ICAP サーバーの設定

ICAP は MaiAgent がシステム管理側で組織ごとに設定します。管理画面には設定ページがありません。有効化や設定変更が必要な場合は、MaiAgent の担当窓口に連絡し、ICAP サーバーの情報を提供してください。各組織で設定できる項目は次のとおりです:

設定項目	説明
ICAP サーバー URL	ICAP サービスの接続 URL です。設定時に接続テストができます

設定項目	説明
有効化	有効にした場合のみ検査します。また、Agent が使用するモデルについても MaiAgent が ICAP 検査を有効にする必要があります。両方を有効にして初めて検査が行われます
ブロックメッセージ	コンテンツがブロックされたときにユーザーに表示するメッセージです
記録保存日数	スキャン記録の保存期間です。デフォルトは30日で、0は永久保存を意味します

6.2 対応する ICAP サービス

MaiAgent は次の主要な ICAP サービスと互換性があります:

Symantec Protection Engine: エンタープライズ向けのウイルス対策とコンテンツフィルタリングです

McAfee Web Gateway: ゲートウェイレベルのコンテンツスキャンです

Trend Micro IWSVA: Web セキュリティとコンテンツスキャンを統合したサービスです

Kaspersky Scan Engine: Kaspersky の ICAP スキャンエンジンです

ClamAV (c-icap 経由): オープンソースのウイルス対策ソリューションです

6.3 パフォーマンスに関する考慮事項

システムのパフォーマンスを確保するため、次の方法を推奨します:

非同期スキャン: 大きなファイルをバックグラウンドタスクでスキャンし、アップロードのレスポンスをブロックしません

キャッシュ: 同一ファイル（ハッシュ値が同じファイル）のスキャン結果をキャッシュします

ICAP コネクションプール: ICAP サーバーとの永続接続を維持し、接続のオーバーヘッドを削減します

負荷分散: 複数の ICAP サーバーインスタンスでスキャンの負荷を分散します

7. MaiAgent の ICAP 統合の技術的な利点

7.1 セキュリティ上の利点

多層防御: ファイルの保存前にスキャンを行い、悪意のあるコンテンツを防ぎます

即時ブロック: 脅威を検出すると即座にブロックし、システムへの保存を防ぎます

専門エンジン: 業界をリードするウイルス対策および DLP エンジンを統合します

完全な記録: すべてのスキャン活動を詳細に記録し、セキュリティ監査に役立ちます

7.2 コンプライアンス上の利点

標準プロトコル: 業界標準の ICAP プロトコルを使用し、既存の企業セキュリティ基盤と容易に統合できます

監査証跡: 完全なスキャン記録でコンプライアンス要件を満たします

柔軟な設定: 業界ごとのコンプライアンス要件に応じてスキャン方針を調整できます

データ保護: DLP エンジンに対応し、機密情報の漏えいを防ぎます

7.3 運用上の利点

疎結合のアーキテクチャ: ICAP スキャンロジックをアプリケーションから分離し、保守を容易にします

水平スケーリング: ICAP サーバーを容易に追加でき、より多くのスキャンリクエストを処理できます

一元管理: 企業は既存の ICAP 基盤を使い、すべてのアプリケーションのコンテンツスキャンを一元管理できます

詳細なログ: 完全なスキャンログで、トラブルシューティングとパフォーマンスの最適化を支援します

8. 関連ドキュメント

[AI セキュリティ保護機構 - MaiAgent の多層セキュリティ戦略について説明します](#)

[ファイルアップロードとナレッジベース管理](#)

参考リンク

[ICAP RFC 3507](#)

[Chunked Transfer Encoding \(RFC 7230\)](#)

[Open ICAP Forum](#)


MaiAgent Work | 従業員の生産性向上のための連携

MaiGPT をシステムに追加します

このページでは、「自社システムに MaiGPT を追加したい」というエンジニア向けに、最初から最後までの手順を説明します。自社のポータルサイト、社内ワークスペース、顧客向けに運用する SaaS のいずれでも、利用者が **MaiAgent 組織のメンバー**（従業員や担当者）であれば手順は同じです。各ステップで必要な作業をここにまとめています。詳細が必要な場合はリンク先を参照してください。

利用者が組織メンバーではなく、自社の顧客、会員、匿名の訪問者である場合、MaiGPT 製品自体は提供できません。独自の AI Agent+MaiGPT ウィンドウモードを利用してください。連絡先の本人情報との連携については、ソフトウェアベンダー向け統合ガイドを参照してください。

全体像



Mermaid 図表

設定が完了すると、従業員が自社システムにログインした際に、ページ内に MaiGPT が表示されます。画像生成、Deep Research、コネクタを利用でき、権限、利用枠、会話履歴は MaiAgent のメンバー情報に紐づきます。MaiAgent に別途ログインする必要はなく、MaiAgent の存在を意識する必要もありません。

事前準備

項目	入手先・設定方法
MaiGPT と ID 同期を含むプランの MaiAgent 組織	不明な場合は営業担当にお問い合わせください
組織の所有者、または「組織概要」の管理権限を持つユーザーが保有する組織 API Key	取得方法は クイックスタート を参照してください
MaiGPT の Web Chat ID	<code>GET /api/v1/web-chats/</code> のレスポンスで、名前が <code>MaiGPT</code> 、 <code>accessType</code> が <code>web</code> の項目です

項目	入手先・設定方法
ロールの作成と権限設定	管理画面の「組織設定 → 組織概要 → ロール権限の編集」で、例えば「従業員」ロールを作成し、MaiGPT の利用権限を有効にしてください（ 設定方法 ）。メンバーの機能はすべてロールによって決まります。この設定がないと、以降の作業を行っても利用できません
メンバーの登録元を決定	次のセクションの 3 つの方法から選択してください

ステップ 1：メンバーを登録する

利用者は、まず MaiAgent 組織のメンバーになる必要があります。次の 3 つから、最も手軽な方法を選んでください。

組織内ですでに MaiAgent を利用しているユーザーがいる場合も、SCIM 連携によって既存のアカウントが無効になったり、重複アカウントが作成されたりすることはありません。SCIM の管理対象になった既存メンバーは、以降、自社システムと同期されます。詳細は[既存のアカウントとメンバーへの影響](#)を参照してください。

自社システムにユーザー管理機能がある場合（推奨）

自社システムでユーザーを追加、変更、無効化するイベントから MaiAgent の SCIM エンドポイントを呼び出すと、メンバー情報をリアルタイムで一致させられます。

管理画面の「組織設定 → ID 同期」で SCIM を選択し、「接続情報」タブから Endpoint URL と Token をコピーしてください（Token は一度しか表示されないため、サーバーの環境変数に保存してください）

[リアルタイム同期のページ](#)にある `MaiAgentMembers` クライアントをプロジェクトに追加し、イベント内で呼び出してください。

```
members = MaiAgentMembers() # 環境変数 MAIAGENT_SCIM_URL MAIAGENT_SCIM_TOKEN を読み込みます

# ユーザーを追加します
user.maiagent_member_id = members.on_user_created(
    external_id=user.id, email=user.email, name=user.display_name, groups=["従業員"],
)
# 名前や部署を変更します
members.on_user_updated(user.maiagent_member_id, user.id, user.email,
user.display_name, ["従業員"])
# 利用停止や退職に対応します
members.on_user_deactivated(user.maiagent_member_id)
```

初回の導入時に、既存ユーザー全員に対して `on_user_created` を一度実行してください（冪等です。一括補完を参照してください）。以降はイベントで同期を維持します。

名簿のみがある場合（人事データのエクスポート、Excel、データベース）

名簿同期ツールを利用してください。4 項目（社員番号、Email、氏名、ロール）の CSV または JSON を用意し、SCIM 接続用の環境変数を設定します。まず `--dry-run` で実行計画を確認してから本実行し、その後は毎日 1 回実行するようにスケジュールを設定してください。名簿にあるユーザーは作成または更新され、名簿から削除されたユーザーは無効化されます。

Okta／Entra ID／JumpCloud がある場合

IdP のプロビジョニング設定に SCIM の Endpoint URL と Token を入力してください。IdP がユーザーとグループを自動的に送信します。詳細はIdP からの送信を参照してください。

実際の連携で特につまづきやすい、次の 3 点を確認してください。

ロール名を管理画面で作成したロールと一致させてください： SCIM でメンバーを作成する際の `groups` の名前は、管理画面で権限を設定済みのロール名です。一致しない場合、**権限のない新しいロール**が自動作成されます。

Email がアカウントのキーです： `userName` は、後でトークンを発行する際に使用する Email です。作成後は SCIM で Email を変更できません。

SCIM で作成したアカウントにはパスワードがありません： この方法では従業員は MaiAgent にログインしません。これは意図した動作です。MaiGPT の Web 版や App も利用可能にする場合は、別途 SSO を設定してください。

ステップ 2：バックエンドでメンバートークンを発行する

バックエンドに、**ログイン済みのユーザー**だけが呼び出せるエンドポイント（例えば `GET /maigpt-token`）を作成してください。内部では組織 API Key を使用し、MaiAgent にそのメンバーの短期トークンを発行してもらいます。

```
curl -X POST https://api.maiagent.ai/api/v1/members/embed-tokens/
-H "Authorization: Api-Key <組織 API Key>"
-H "Content-Type: application/json"
-d '{"email": "alice@acme.com"}'
```

成功すると `201` が返ります。

```
{
  "accessToken": "<メンバーの短期 JWT>",
  "organizationId": "8d2f ... - ... ",
  "expiresAt": 1789906401000,
  "member": { "id": "c1a4 ... ", "userId": "5e77 ... ", "email": "alice@acme.com",
  "name": "Alice" }
}
```

レスポンス全体をそのままフロントエンドに返してください。ルールとステータスコードは次のとおりです。

仕様	説明
有効期間は 15 分、refresh token は発行されません	更新はフロントエンド SDK が自動処理します（ステップ 3）。バックエンドは呼び出されるたびにトークンを発行するだけです。 毎回新しいトークンを発行し、キャッシュしないでください
トークンは MaiGPT の会話エンドポイントでのみ利用できます	このトークンで <code>/api/v1/</code> のどの API を呼び出しても 401 が返るため、漏えいしても組織データにアクセスできません
401 / 403	Api-Key が使用されていない、または Key の保有者が所有者でも組織管理者でもありません
404	この Email は、この組織の有効なメンバーではありません。ステップ 1 が未実施、またはすでに無効化されています
トークンを発行するたびに監査ログが残ります	組織の API リクエストログで確認できます。レスポンス内のトークンは記録されません

パラメータや詳細は[メンバートークンの発行](#)を参照してください。

ステップ 3：フロントエンドに埋め込む

MaiGPT を配置するページに埋め込みコードを追加し、`auth.getToken` にステップ 2 のエンドポイントを指定してください。それ以外は SDK が処理します（初期化時のトークン取得、有効期限前の自動再取得、同じ会話の継続）。

```

<div id="maigpt-container" style="height: 720px;"></div>
<script>
  window.maiagentChatbotConfig = {
    webChatId: '<MaiGPT の Web Chat ID>',
    baseUrl: 'https://chat.maiagent.ai/web-chats',
    enabledWindowModes: ['maigpt'],
    targetElement: '#maigpt-container',
    maigptTitle: 'Acme GPT',           // 任意：左上に表示するブランド名
    locale: 'zh-TW',                  // 任意：インターフェースの言語
    auth: {
      getToken: async () => {
        const res = await fetch('/maigpt-token', { credentials: 'include' })
        const { accessToken, organizationId, member } = await res.json()
        return { accessToken, organizationId, sourceId: member.userId }
      },
    },
  }
</script>
<script src="https://chat.maiagent.ai/js/embed.min.js" defer></script>

```

sourceId には必ずレスポンスの member.userId を設定してください。member.id や自社システムのユーザー ID ではありません。MaiGPT はこの値で会話をメンバーに紐づけます。誤った値を設定すると匿名の会話になり、そのメンバーの履歴を表示できません。

コンテナの高さは自分で指定してください。SPA ではコンテナがマウントされてから SDK を読み込んでください。`baseUrl` と SDK の URL は SaaS のアドレスです。プライベートデプロイの場合は自社のドメインに置き換えてください。レイアウトやその他のパラメータは [MaiGPT モードの埋め込み](#) を参照してください。

ステップ 4：ログアウトと退職に対応する

イベント	必要な対応	結果
ユーザーが自社システムからログアウト	フロントエンドで <code>MaiAgent.auth.signOut()</code> を呼び出してください	iframe が本人情報を消去し、更新を停止します。発行済みトークンは最大でさらに 15 分間有効です
ユーザーの退職／利用停止	ステップ 1 の無効化を実行してください (<code>on_user_deactivated</code> 、名簿からの削除、IdP での無効化)	以降のトークン発行は <code>404</code> を返し、埋め込みページは利用できなくなります。会話と利用枠の記録は保持されます
復職	ステップ 1 の再有効化を実行してください	ロールと履歴が復元されます

ステップ 5：受け入れテスト

次の項目を順番に確認してください。それぞれに明確な判定基準があります。

メンバーが存在し、ロールが割り当てられています：管理画面の「メンバー管理」に対象者が表示され、権限設定済みのロールが割り当てられていることを確認してください。

トークン発行に成功します：ステップ 2 の curl が `201` を返し、存在しない Email を指定すると `404` を返すことを確認してください。

会話できます：埋め込みページで MaiGPT を開き、メッセージを送って返信を受け取ってください。そのメンバーとして MaiGPT の Web 版にログインした場合（SSO がある場合）、または管理画面の会話記録で、この会話を確認できることを確認してください。

機能が正しく利用できます：画像生成を依頼してください。ロールでコネクタと Deep Research が有効になっている場合は、それらの入口が表示されます。

更新を意識せずに利用できます：ページを 15 分以上開いたままにしてからメッセージを送ってください。ページを再読み込みせずに、同じ会話を継続できることを確認してください。

ログアウトが有効になります： `signOut()` 後のメッセージ送信が拒否され、メンバーを無効化するとステップ 2 が `404` を返すことを確認してください。

導入後

SCIM Token と API Key のローテーション：SCIM Token の作成から 180 日を超えると管理画面に通知されます。再生成すると古いトークンは即座に無効になるため、サーバーの環境変数も更新してください。

プランの容量：メンバー数は組み込み Agent の席数と各メンバーの Credits 利用枠に影響します。[メンバーの Credits 利用枠管理](#)を参照してください。

監査：トークン発行は毎回、組織の API リクエストログに記録されます。SCIM の同期は毎回、管理画面の「ID 同期 → 同期ログ」に記録されます。

トラブルシューティング

現象	原因	対処方法
トークン発行で <code>404</code> が返ります	Email がこの組織の有効なメンバーではありません	ステップ 1 に戻り、メンバーが存在すること、無効化されていないこと、Email が一致すること（大文字・小文字は区別しません）を確認してください
トークン発行で <code>403</code> が返ります	API Key の保有者が所有者ではなく、組織の管理権限也没有せん	管理者が発行した Key を使用してください

現象	原因	対処方法
チャットウィンドウに「会話の作成に失敗しました (400) MaiGPT を利用する権限がありません」と表示されます	メンバーのロールに MaiGPT の利用権限がない、または <code>auth</code> が渡されていません	管理画面のロール権限で MaiGPT を有効にし、 <code>getToken</code> が <code>accessToken</code> と <code>organizationId</code> を返すことを確認してください
会話が匿名になり、履歴が表示されません	<code>sourceId</code> が誤っています	<code>member.userId</code> を使用してください
15 分後にメッセージ送信が失敗します	<code>getToken</code> が呼び出されていないか、失敗しています (ブラウザの console の <code>[MaiAgent]</code> エラーを確認してください)	ログイン済みのユーザーがエンドポイントを利用でき、レスポンス形式が正しいことを確認してください
メンバーは作成されたのに何も利用できません	ロールが割り当てられていない、またはロールの権限が空です	管理画面でロール権限を設定し、SCIM で同じ名前を指定して割り当ててください
Email の変更が反映されません	SCIM では Email を変更できません	管理画面で変更するか、古いアカウントを無効化して新しい Email で作成してください

その他の SCIM エラーコードは[名簿同期ツールのエラー一覧](#)を参照してください。

関連資料

[メンバーの登録：SCIM／招待／SSO](#) — SCIM API の完全なリファレンスと 3 つの方法の比較です

[リアルタイム同期：ユーザーイベントから呼び出す／名簿同期ツール](#)

[MaiGPT との連携：適切な Agent の選択と機能の整備](#) — MaiGPT 製品と独自 Agent の違い、メンバーの本人情報を使用する埋め込みの全パラメータを説明します

[Web Chat の埋め込みと SDK／MaiGPT モードの埋め込み](#)

MaiGPT 連携：適切な Agent の選択と機能の補完

MaiAgent プラットフォームでは、「MaiGPT」は異なる 2 つのものを指します。連携前に違いを理解しておく
と、確認のやり取りを大幅に減らせます。

	MaiGPT 製品（組織に組み込まれた Agent）	MaiGPT ウィンドウモード（Web Chat SDK のレイアウトの一種）
概要	各組織に自動で提供され、MaiAgent が一元管理する企業向け AI ワークスペースです。AI 画像生成、Deep Research、コネクタなどが組み込まれています。 <u>MaiGPT とは？</u> をご覧ください	<code>enabledWindowModes: ['maigpt']</code> で有効にする ChatGPT のようなフルインターフェース（サイドバーの会話履歴、検索、設定）です。フロントエンドの表示形式のみを提供します
利用できるユーザー	組織のメンバーがログインして利用します（Web、iOS App、LINE、Microsoft Teams）。権限は <u>ロール別の利用権限</u> で制御します	匿名の訪問者や <u>連絡先の認証情報</u> を使用する場合も含め、どの Web Chat にも適用できます
自社システムへの埋め込み	組織メンバー向けにのみ利用できます 。会話の作成にはメンバーの認証情報と <code>maigpt_access</code> 権限が必要です。Web Chat ID だけで直接埋め込むと <code>400 MaiGPT を利用する権限がありません。</code> が返ります。メンバー向けに埋め込む場合は、 <u>メンバー認証による埋め込み</u> に従い、自社バックエンドでメンバートークンを発行します	可能です 。本ページの第 2、3 節で説明します
カスタマイズ	できません 。指示、モデル、ツール、スキルはすべてプラットフォームが一元設定します。組織側はロール権限によって利用範囲を制限することだけができます	可能です 。インターフェースの背後で動く AI Agent は自分で作成するため、指示、モデル、ツール、ナレッジベースをすべて自分で決められます

結論：用途は 2 つに分かれます。**組織メンバーではない自社の顧客向けには、独自の AI Agent を作成し、必要なツールを追加して MaiGPT ウィンドウモードで埋め込みます**（第 2、3 節）。**組織メンバー向けに MaiGPT 製品そのものの機能**（画像生成、Deep Research、コネクタ、ロール権限）を利用する場合は、メンバー認証による埋め込み（第 5 節）を使用し、自社バックエンドでメンバーの短期トークンを発行します。

1. よくある症状と対処方法

表示される症状	原因	対処方法
インターフェースは MaiGPT のように見えるものの、応答は通常のチャットと同じで、画像生成を依頼すると AI が「画像を生成できません」と答えます	通常の AI Agent を埋め込んでおり、(1) 応答モードが Agent モード ではない、または (2) 画像生成などのツールが設定されていません	第2節 に従って Agent モードに切り替え、ツールを追加します
チャットウィンドウが開かず、「会話の作成に失敗しました (HTTP 400)」と表示され、API が MaiGPT を利用する権限がありません。 を返します	埋め込んだ Web Chat ID が組織に組み込まれた MaiGPT 製品のもので、訪問者にメンバーの認証情報がありません	顧客向け → 独自 Agent の Web Chat ID に変更します (第3節)。 メンバー向け → メンバー認証による埋め込み に従ってメンバートークンを渡します
管理画面の AI Agent 一覧 API に MaiGPT が見つかりません	<code>GET /api/v1/chatbots/</code> は組織が独自に作成した Agent だけを返し、MaiGPT 製品は含みません	これは想定どおりの動作です。連携の対象には独自に作成した Agent を使用します

 組織に組み込まれた MaiGPT の Web Chat を埋め込むと、チャットウィンドウに会話作成の失敗が表示されます

組織に組み込まれた MaiGPT の Web Chat の埋め込み：訪問者はログイン済みのメンバーではないため、会話の作成が拒否されます (HTTP 400)

2. 画像生成やツールの利用ができる AI Agent を作成する

以下では「AI 画像生成」を例に説明します。ほかの機能（Web 検索、Web ページの取得、MCP ツール、自社の API ツール）も同じ方法で追加できます。

AI Agent を作成する

管理画面の「AI 機能 → AI アシスタント」で新しい AI Agent を作成し、ロール指示とモデルを設定します。操作方はユーザーマニュアルの[Agent の作成](#)をご覧ください。

応答モードを「Agent モード」に切り替える

Agent の「応答モード設定」を開き、応答モードを **Agent モード** に変更します。

ツールを呼び出すのは Agent モードだけです。デフォルトの「RAG 質疑応答」モードは応答が速いものの、ツールは一切使用しません。画像生成ツールを追加したのに画像を生成しない場合、これが最もよくある原因です。

ツールを追加する

Agent の「ツール」 ページを開き、「ツールを選択」をクリックして、必要な組み込みツールを選択します。
例：

画像生成： `Global_Image_Tool_OpenAI_GPT_Image_2` 、 `Global_Image_Tool_Gemini_3` など（1 つ選択
すれば十分です。モデルの違いは組み込み AI 画像生成ツールをご覧ください）

Web 検索： `Global_Tavily_Search_Tool`

Web ページの取得： `Global_Web_Fetch_Tool`

自社システムの API ツール または MCP ツール

詳しい操作方法是ユーザーマニュアルの Agent へのツールの設定 をご覧ください。

Web Chat の会話プラットフォームを作成する

「カスタマーサポート会話 → 会話プラットフォーム」で、この Agent に **Web Chat** を追加し、 `webChatId` を取得します。操作方法是 会話プラットフォームの連携：Web サイト をご覧ください。

API で自動化する（ISV による顧客向け環境の構築）

上記の 4 ステップには、それぞれ対応する API があります。ソフトウェアベンダーが顧客ごとの利用開始時にプログラムで設定する用途に適しています。認証方法と API Key の取得方法は クイックスタート をご覧ください。

1. 組み込みツールの一覧を取得し、画像生成ツールの id を取得します

GET /api/v1/tools/

2. AI Agent を作成します：応答モードを agent に設定し、ツールを追加します

POST /api/v1/chatbots/

```
{
  "name": "Acme GPT",
  "instructions": "あなたは Acme 社の AI アシスタントです。日本語で回答してください。",
  "largeLanguageModel": "<LLM id>",
  "embeddingModel": "<embedding model id>",
  "rerankerModel": "<reranker model id>",
  "replyMode": "agent",
  "tools": ["<Global_Image_Tool_OpenAI_GPT_Image_2 の id>"]
}
```

3. Agent の Web Chat 会話プラットフォームを作成します（応答の channel.id が webChatId です）

POST /api/v1/inboxes/

```
{
  "name": "Acme GPT",
  "chatbot": "<chatbot id>",
  "channelType": "web",
  "channel": {
    "name": "Acme GPT",
    "theme": { "primaryColor": "#1890ff", " ... ": " ... " },
    "darkTheme": { "primaryColor": "#404040", " ... ": " ... " }
  }
}
```

既存 Agent のモード変更やツールの追加には `PATCH /api/v1/chatbots/{id}`

を使用します。`tools` にはツール id の配列全体を渡します（全体を置き換えます）

`theme` と `darkTheme` は必須です。フィールドの一覧は、まず `GET /api/v1/web-chats/{既存の webChatId}`

で既存の設定を取得してコピーできます

Web Chat は必ず `POST /api/v1/inboxes/` で受信トレイと一緒に作成します。`POST /api/v1/web-`

`chats/` を直接呼び出すと、受信トレイのない孤立した Web Chat が作成され、埋め込み時に 404 が返ります

3. MaiGPT ウィンドウモードで埋め込む

第2節で取得した `webChatId` を使用し、MaiGPT モードの埋め込みに従って埋め込みコードをページに追加します。

```
<div id="maigpt-container" style="height: 720px;"></div>
<script>
  window.maigptChatbotConfig = {
    webChatId: '<第 2 節で作成した webChatId>',
    baseUrl: 'https://chat.maigpt.ai/web-chats',
    enabledWindowModes: ['maigpt'],
    targetElement: '#maigpt-container',
    maigptTitle: 'Acme GPT',
  }
</script>
<script src="https://chat.maigpt.ai/js/embed.min.js" defer></script>
```

Agent がログイン中のユーザーを識別し、その権限で自社 API を呼び出せるようにするには、ソフトウェアベンダー向け連携ガイドに従って `contactId` または `auth` を追加します。

検証：同じ埋め込みコードで機能を追加する前と後

以下の 2 枚の画像は、同じ AI Agent と同じ埋め込みコードを使用しています。違いは「応答モード+ツール」の設定だけです。

追加前：RAG 質疑応答モード、ツールなし



MaiGPT ウィンドウモードで、ツールを設定していない Agent が画像を生成できないと回答します

インターフェースは MaiGPT ウィンドウモードですが、Agent は「画像を生成、作成、制作できません」と回答します

追加後：Agent モード+画像生成ツール



MaiGPT ウィンドウモードで、画像生成ツールを設定した Agent が画像を直接生成します

同じ埋め込みコードで、Agent が画像生成ツールを呼び出し、会話内に直接画像を生成します

4. MaiGPT 製品そのものを使用すべきケース

「自社製品に埋め込んで顧客に提供する」のではなく、「社員が使える ChatGPT 相当の社内 Agent が欲しい」場合は、MaiGPT 製品を直接使用する方法が最も簡単です。

社員は組織メンバーとしてプラットフォームにログインするだけで利用できます。Web 版、iOS App、LINE、Microsoft Teamsからアクセスできます

画像生成、Deep Research、コネクタ、スキルはすべて組み込まれています。管理者はロール別の利用権限で、誰がどの機能を利用できるかを決めるだけです

社内専用の知識を追加するには、メンバーが参照できる範囲にナレッジベースを設定します。別の Agent を作成する必要はありません

「自社システムに埋め込むが、ユーザーは組織メンバー」→ 第 5 節のメンバー認証による埋め込みを使用します。「メンバー以外（顧客、登録ユーザー）向け」「自社の API ツールを追加したい」「指示やモデルを変更したい」のいずれかに該当する場合は、第 2、3 節の独自 Agent を作成する方法を使用します。

5. メンバー認証による埋め込み：組織メンバー向けに MaiGPT 製品を自社システムに埋め込む

最初から順に進めたい場合は、MaiGPT を自社システムに追加するをご覧ください。本節は各パラメータの完全なリファレンスです。

対象となるケース：自社システムのユーザーが**MaiAgent 組織のメンバーでもあり**（企業ポータル、社員用ワークスペース、ISV が管理する企業内システムなど）、別の Agent を作成せずに MaiGPT 製品そのものを利用したい場合です。**自社バックエンド**が組織 API Key を使用してログイン中のメンバーの短期トークンを発行し、フロントエンドでは SDK の既存のメンバー認証情報の注入設定を使用して MaiGPT の Web Chat を埋め込みます。

```
sequenceDiagram
    participant U as メンバーのブラウザ
    participant P as 自社バックエンド
    participant M as MaiAgent API
    participant W as MaiGPT Web Chat
    U->>P: ログイン済みで MaiGPT を含むページを開きます
    U->>P: SDK が auth.getToken を呼び出し、自社バックエンドにリクエストします
    P->>M: POST /api/v1/members/embed-tokens/ (Api-Key、メンバーの email を指定)
    M-->>P: accessToken (15 分)、organizationId、member.userId
    P-->>U: getToken に返します
    U->>W: SDK がメンバーとして会話を作成し、メッセージを送信します
    Note over U,W: トークンの期限が近づくと
    W->>P: iframe が SDK に通知し、SDK が getToken を再度呼び出して自動更新します
```

Mermaid 図表

前提条件

組織 API Key が必要です。所有者は組織オーナー、またはロールに「組織概要」の管理権限を持つユーザーである必要があります。メンバーを管理できる人が発行した Key だけが、メンバーの代理でトークンを発行できます。API Key の取得方法はクイックスタートをご覧ください

埋め込み先のユーザーは既にその組織のメンバーで、ロールに MaiGPT の利用権限が必要です（MaiGPT のロール別利用権限）。メンバーが存在しない場合、トークン発行は 404 を返し、自動でメンバーを作成しません。メンバーになる方法（SCIM プロビジョニング API、管理画面からの招待、SSO）はメンバーのプロビジョニングをご覧ください。ISV が管理する場合の標準的な連携方法は、SCIM でメンバーを作成し、本節の方法でトークンを発行する構成です

MaiGPT の Web Chat ID：`GET /api/v1/web-chats/` の応答に含まれる、名前が `MaiGPT` で `accessType` が `web` のレコードです

ステップ 1：バックエンドでメンバートークンを発行する

自社バックエンドにログイン済みのユーザーだけが呼び出せるエンドポイント（例：`GET /maigpt-token`）を作成し、内部で MaiAgent を呼び出します。フロントエンドの SDK が必要に応じてこのエンドポイント呼び出します。

```
curl -X POST https://api.maiagent.ai/api/v1/members/embed-tokens/
-H "Authorization: Api-Key <自社の組織 API Key>"
-H "Content-Type: application/json"
-d '{"email": "alice@acme.com"}'
```

`email` または `memberId` のどちらかを指定します（`memberId` は MaiAgent のメンバー ID です）。成功時は `201` が返ります（`expiresAt` はエポックミリ秒です）。

```
{
  "accessToken": "<メンバーの短期 JWT>",
  "organizationId": "8d2f ... - ... ",
  "expiresAt": 1789906401000,
  "member": {
    "id": "c1a4 ... - ... ",
    "userId": "5e77 ... - ... ",
    "email": "alice@acme.com",
    "name": "Alice"
  }
}
```

ステータスコード	意味
400	<code>email</code> と <code>memberId</code> の両方を指定した、またはどちらも指定していません
401	Api-Key で認証していません（メンバーのログイントークンや匿名リクエストは拒否されます）
403	API Key の所有者が組織オーナーではなく、組織管理権限もありません
404	指定したメンバーが存在しない、無効になっている、またはこの Key の組織に属していません

トークンのルール：有効期間は 15 分で固定され、refresh token は発行されず、延長もできません。同じメンバーに繰り返し発行でき、古いトークンも期限までは有効です。このトークンは Web Chat の会話にのみ使用できます（会話の作成、メッセージ送信、引き継ぎ後の会話継続の 3 つの呼び出し）。/api/v1/ の任意のエンドポイント、その他の会話管理操作、WebSocket に使用すると、すべて 401 が返ります。発行のたびに組織の API リクエストログに監査用の記録が残ります（応答内のトークンは記録されません）。

ステップ 2：フロントエンドの SDK にトークン取得関数を渡す

埋め込み設定は第 3 節と同じですが、`auth.getToken` を追加し、`webChatId` を MaiGPT の Web Chat ID に変更します。

```
<div id="maigpt-container" style="height: 720px;"></div>
<script>
  window.maiagentChatbotConfig = {
    webChatId: '<MaiGPT の Web Chat ID>',
    baseUrl: 'https://chat.maiagent.ai/web-chats',
    enabledWindowModes: ['maigpt'],
    targetElement: '#maigpt-container',
    auth: {
      // SDK の初期化時に 1 回呼び出され、その後はトークンの期限が近づくたびに再度呼び出されて自動更新します。タイマーは不要です
      getToken: async () => {
        const res = await fetch('/maigpt-token', { credentials: 'include' }) // 自社バックエンドです。ステップ 1 を参照してください
        const { accessToken, organizationId, member } = await res.json()
        return { accessToken, organizationId, sourceId: member.userId }
      },
    },
  }
</script>
<script src="https://chat.maiagent.ai/js/embed.min.js" defer></script>
```

`getToken` が返すオブジェクトのフィールド：

フィールド	必須	説明
<code>accessToken</code>	✓	ステップ 1 の応答に含まれる <code>accessToken</code> です
<code>organizationId</code>	✓	ステップ 1 の応答に含まれる <code>organizationId</code> です
<code>sourceId</code>	推奨	ステップ 1 の応答に含まれる <code>member.userId</code> です。 <code>auth.sourceId</code> に設定することもできます。両方を指定した場合は <code>auth.sourceId</code> が優先されます

`auth` は `maiagentChatbotConfig` 内に記述する必要があります。これにより SDK は、チャットウィンドウを作成するときに、メンバーの認証情報の注入が完了してから最初の会話を作成することを認識できます。SDK の読み込み後に `MaiAgent.auth.setup()` を呼び出す方法では、認証情報の注入前に最初の会話が匿名で作成され、拒否される場合があります。

sourceId は応答に含まれる member.userId である必要があります。member.id や自社システムのユーザー番号ではありません。MaiGPT はこの値を使って会話をメンバーに紐付けます。誤った値を指定すると匿名の会話になり、そのメンバーの MaiGPT 履歴が表示されません。

有効期限と更新の仕組み

トークンの有効期間は 15 分です。iframe は期限の 60 秒前に SDK に通知し、SDK は `getToken` を再度呼び出して新しいトークンを取得し、注入し直します。**ページや iframe を再読み込みせず、同じ会話をそのまま継続できます**。ユーザー側で操作する必要はありません。

`getToken` は毎回 MaiAgent に新しいトークンを要求する必要があり、キャッシュした値を返してはいけません。SDK はトークン自体の有効期間に基づいて次の更新を予定します。前回と同じトークンを返すと失敗とみなされ、次の項目の再試行処理に進みます。

`getToken` が失敗した場合（ユーザーがログアウトした、自社バックエンドが 401 を返した場合など）、SDK は 30 秒、60 秒、120 秒後にそれぞれ 1 回再試行します。それでも失敗すると停止し、コンソールにエラーを記録します。トークンの期限が切れた後は次のメッセージの送信が失敗し、既存のエラー通知が表示されます。会話と送信済みのメッセージは消えません。

ユーザーが自社システムからログアウトするときは `MaiAgent.auth.signOut()` を呼び出します。SDK は認証情報を削除し、更新を停止します。発行済みトークンは最大であと 15 分有効です。別のユーザーがログインした場合は、`MaiAgent.auth.setup()` を再度呼び出すだけで対応できます。前のユーザーの進行中の更新処理は無効になります。

Web Chat で Source ID の署名検証 を有効にしている場合、署名は 1 回限りです。SDK は更新時に最初の `ts` / `sig` を再利用しません。`getToken` の戻り値に新しい署名も含めてください（`{ accessToken, ts, sig }`）。

`getToken` を使用せず、静的な `auth.accessToken` を直接指定する場合、SDK は更新しません。15 分後に自分で `MaiAgent.auth.setup()` を再度呼び出す必要があります。

この方法と独自 Agent の選び方

	メンバー認証による MaiGPT の埋め込み（本節）	独自 Agent+MaiGPT ウィンドウモード（第 2、3 節）
ユーザー	組織メンバーである必要があります	誰でも利用できます（顧客、登録ユーザー、匿名）
機能	MaiGPT の全機能：画像生成、Deep Research、コネクタ、スキル。ロール権限に従います	選択したツールとナレッジベースです
指示／モデルのカスタマイズ	できません（プラットフォームが一元設定します）	可能です
バックエンドの実装	トークン発行 API を呼び出すエンドポイントが 1 つ必要です	不要です（任意で連絡先の認証情報の同期を追加できます）

	メンバー認証による MaiGPT の埋め込み（本節）	独自 Agent+MaiGPT ウィンドウモード（第 2、3 節）
課金先	そのメンバーのクレジットです	その Agent／Web Chat です

6. よくある質問

- ▶ 管理画面の「会話プラットフォーム」に MaiGPT という Web Chat があります。その埋め込みコードを使用できますか？
- ▶ MaiGPT 製品の画像生成、Deep Research、コネクタを、独自 Agent でも利用できますか？
- ▶ 応答モードは Agent で、画像生成ツールも追加しましたが、画像を生成しません。どうすればよいですか？
- ▶ MaiGPT ウィンドウモードは floating／sidebar と何が違いますか？

MaiAgent Serve | カスタマーサービス連携

ソフトウェアベンダー向け連携ガイド：顧客向けに AI Agent を組み込みます

このページは「MaiAgent Web Chat を自社製品に埋め込み、自社のアカウントシステムと権限連携を行う」ソフトウェアベンダー向けです。ユーザーが貴社のシステムにログインすると、AI Agent がそのユーザーを識別し、会話履歴を参照して、**そのユーザーの権限**で貴社システムの API を呼び出します。

連携は 5 つの段階で進めます。このページでは各段階で行うことと順序を説明し、詳細については対応する技術ドキュメントにリンクしています。

連携の全体像

```
flowchart LR
    subgraph ONCE ["初回の構築"]
        A["Web Chat の埋め込み"] --> B["既存ユーザーの一括補完"]
    end
    subgraph DAILY ["日常運用（アカウントのライフサイクル）"]
        C["ユーザー追加時にコンタクトを作成"] --> D["ログイン時に Token を更新"]
        D --> E["Token 更新時に再同期"]
        E --> F["ログアウト時に認証情報を失効"]
    end
    ONCE --> DAILY
```

Mermaid 図表

このページのユーザーは貴社のお客様です（MaiAgent のコンタクトに対応します）。貴社またはお客様の従業員を連携させ、MaiAgent の組織メンバーにする場合（MaiGPT、ロール権限、Credits の利用枠を使用する場合）は、[メンバープロビジョニング：SCIM／招待／SSO](#)をご覧ください。

中心となる概念は**コンタクト（Contact）**です。貴社システムの各ユーザーが MaiAgent の 1 つのコンタクトに対応します。コンタクトには会話履歴、パーソナライズ属性、ナレッジベースの検索範囲、ツールの認証情報が紐付きます。権限連携のすべての操作は、この「貴社のユーザー ↔ コンタクト」の対応関係と認証情報を維持するものです。概念の説明は[コンタクト（Contact）の概要と連携](#)をご覧ください。

フロントエンドとバックエンドの役割

連携全体を通して、フロントエンドは「チャットウィンドウの読み込み」のみを担当します。Token や API Key を含む呼び出しは、すべてバックエンドから行います：

```

flowchart LR
    subgraph FE ["貴社のフロントエンド"]
        A["埋め込みコードで SDK を読み込み  
config に contactId を指定"]
        B["ログアウト時に signOut を呼び出し"]
    end
    subgraph BE ["貴社のバック  
エンド"]
        C["ログイン／更新：POST setup-contact-credentials"]
        D["一括補完：POST bulk-import"]
        E["データ同期：PATCH contacts"]
        F["ログアウト：DELETE ツールの認証情報"]
    end
    MA["MaiAgent"]
    G["チャットウィンドウ  
chat.maiagent.ai"]
    H["API  
api.maiagent.ai"]
    A --> G
    B --> G
    C --> H
    D --> H
    E --> H
    F --> H

```

Mermaid 図表

`setup-contact-credentials` は API Key が不要な公開エンドポイントです。`bulk-import`、`PATCH`、`DELETE` はすべて `Authorization: Api-Key` 認証が必要で、バックエンドからのみ呼び出せます。

ステップ 1：Web Chat の埋め込み

最初に、埋め込む AI Agent を決めてください。埋め込みで使える機能（画像生成、Web アクセス、ツール呼び出し）は Web Chat の背後の Agent 設定によって決まり、埋め込み方式には依存しません。組織に組み込まれた「MaiGPT」製品はログイン済みメンバー専用で、その Web Chat は外部システムに埋め込めません。貴社製品用の AI Agent を作成し、Agent モードに設定して必要なツールを追加してください。[MaiGPT 連携：適切な Agent の選択と機能の追加](#)をご覧ください。

製品の形態に応じて埋め込み方式を選択します。どちらも同じ SDK とコンタクトの仕組みを使用します：

形態	適した用途	ドキュメント
チャットバブル（floating／sidebar）	カスタマーサポートや相談などの補助機能です	Web Chat の埋め込みと SDK
MaiGPT モード（ChatGPT のような完全なインターフェース）	ページの主要機能エリア、サイト全体の AI 入口です	MaiGPT モードでの埋め込み

ID 連携を行う Web Chat では、この段階で「埋め込みを許可するドメイン」のリストを設定することをお勧めします（管理者が管理画面の会話プラットフォームの基本設定に入力します）。埋め込みと ID 同期 API の呼び出しが可能なオリジンを制限できます。[埋め込みを許可するドメイン](#)をご覧ください。

ステップ 2：初回連携——既存ユーザーの一括補完

既存システムを初めて連携する際は、まず既存ユーザーのコンタクトをまとめて作成します。方法は2つあります：

方法	適した用途	ドキュメント
Excel による一括インポート (<code>POST /contacts/bulk-import/</code>)	大量のユーザー (1 回あたり最大 10,000 行) に適し、ナレッジ検索範囲と API ツールの認証情報も同時に取り込めます	コンタクトの 一括インポート
ID 同期 API をユーザーごとに呼び出す	ログインフローに沿って段階的に補完する場合や、少人数の場合に適しています	既存ユーザー の一括補完

補完時にユーザーの Access Token を取得できなくても問題ありません。先に対応関係を作成し、Token の認証情報はステップ 4 のログインフローで、各ユーザーの次回ログイン時に追加します。

ステップ 3：ユーザー追加時のコンタクト作成

補完後は、貴社システムの「アカウント作成」フローに API 呼び出しを追加し、新規ユーザーが最初から対応するコンタクトを持つようにします：

バックエンドから ID 同期 API (`setup-contact-credentials`) を呼び出し、貴社システムのユーザー識別子を `sourceId` に指定します

返された `contactId` を会員テーブルに保存します (推奨するフィールド設計は[ログインフローへの組み込み位置](#)をご覧ください)

`sourceId` は冪等性キーです。同じ `sourceId` で繰り返し呼び出しても更新のみが行われ、重複作成されません。そのため、このステップはステップ 2、ステップ 4 と安全に併用できます。

ステップ 4：ログインと Token 更新

ログインに成功して Access Token が生成されるたびに、バックエンドから同じ ID 同期 API を再度呼び出し、**新しい Token** (`mcpCredentials`) を渡します。これにより、AI Agent はそのユーザーの ID と権限で貴社システムの API を呼び出せます。Token 更新時も同じ方法で、もう一度呼び出すだけです。同じコンタクトとツールの組み合わせでは、重複作成ではなく更新になります。完全なシーケンス図と注意事項 (非同期呼び出し、失敗してもログインを妨げないこと) は、[コンタクトの ID 同期と Token 更新](#)をご覧ください。

フロントエンドでは、ページで Web Chat を初期化する際に `contactId` を渡します。[ユーザーの識別](#)をご覧ください。

AI に貴社システムの API を呼び出させず、ユーザーを識別するだけでよい場合は、バックエンドを使わず、フロントエンドの config に auth を指定するだけでも対応できます。選択の判断材料は[フロントエンド auth とバックエンド連携の選び方](#)をご覧ください。

ステップ5：ログアウトと認証情報の失効

ログアウト時には、作用範囲が異なる2つの処理があります。両方の実施をお勧めします：

フロントエンド：SDK の `signOut()` を呼び出し、チャットウィンドウを匿名状態に戻します

バックエンド：そのコンタクトのツール認証情報を削除し、AI がそのユーザーとしてツールを呼び出すことを即座に防ぎます

API の詳細と両者の違いは、[ログアウトと認証情報の失効](#)をご覧ください。

連携チェックリスト

段階	操作	ドキュメント
構築	独自の AI Agent を作成します：Agent モード＋画像生成などのツール追加＋Web Chat の作成です	MaiGPT 連携：適切な Agent の選択と機能の追加
構築	Web Chat を埋め込みます（通常または MaiGPT モード）	Web Chat の埋め込みと SDK／MaiGPT モード
構築	管理画面の会話プラットフォームの基本設定に「埋め込みを許可するドメイン」を入力します	埋め込みを許可するドメイン
構築	会員テーブルに <code>maiagent_contact_id</code> フィールドを追加します	ログインフローへの組み込み位置
構築	既存ユーザーを一括補完します	コンタクトの一括インポート
運用	アカウント作成フローで ID 同期 API を呼び出します	コンタクトの ID 同期と Token 更新
運用	ログイン／Token 更新フローで認証情報を更新します	呼び出しのタイミング
運用	ログアウトフローで認証情報を失効させます	ログアウトと認証情報の失効
応用	部門、会員ランクなどのパーソナライズ属性を同期します	コンタクトデータの同期
応用	クエリメタデータでユーザーごとのナレッジベース検索範囲を制限します	ナレッジ管理権限（Query Metadata）

Web Chat の埋め込みと SDK

ウェブページに埋め込みコードを追加するだけで、MaiAgent の AI Agent をウェブサイトに取り込みます。埋め込みコードが `embed.min.js`（以下、SDK）を読み込むと、SDK はページ上にチャットボタンと iframe のチャットウィンドウを作成し、プログラムから操作できるグローバルな `MaiAgent` JavaScript API を提供します。

このページは、Web Chat の埋め込みに関する完全な技術リファレンスです。関連するトピックは次のとおりです。

MaiGPT との連携：適切な Agent の選択と機能の追加 — MaiGPT 製品と MaiGPT ウィンドウモードの違い、および埋め込んだ Agent で画像生成やツール利用を有効にする方法です

Web Chat の MaiGPT モードでの埋め込み — ChatGPT のような多機能の会話インターフェースです

Web Chat へのページ Context の注入 — ページ情報を LLM System Prompt に注入します

連絡先の ID 同期と Token の更新 — バックエンドで連絡先と認証情報を作成します

ソフトウェアベンダー向け連携ガイド — 埋め込みと権限連携の全体の流れ（一括補完作成、ログイン時の同期、ログアウト時の失効）を説明します

1. クイックスタート

ページの `<body>` の前に次のコードを追加します。

```
<script>
  window.maiagentChatbotConfig = {
    webChatId: 'your-web-chat-id',
    baseUrl: 'https://chat.maiagent.ai/web-chats',
    primaryColor: '#1890ff',
  }
</script>
<script src="https://chat.maiagent.ai/js/embed.min.js" defer></script>
```

`webChatId` は管理画面の Web Chat 設定ページで取得します（会話プラットフォームとの連携：ウェブサイト上を参照してください）。管理画面で生成する埋め込みコードには自動で設定されます）

`baseUrl` と SDK の URL は SaaS 環境（`chat.maiagent.ai`）の例です。プライベートクラウド／オンプレミス環境では、お使いの環境のドメインに置き換えてください

`window.maiagentChatbotConfig` は必ず SDK スクリプトの読み込み前に定義してください

デフォルトでは、ページの右下にチャットボタンが表示されます。クリックするとフローティングチャットウィンドウが開き、ユーザーは floating と sidebar の2つのウィンドウモードを切り替えられます。

初期化のタイミング

SDK は読み込み後に `document.body.onload` ハンドラーを登録して初期化します。通常、手動操作は不要です。初期化のタイミングを制御したい場合（SPA でコンテナのマウントを待つ場合や、描画を遅延させる場合など）は、次の方法を使用します。

スクリプトを遅延読み込みする：適切なタイミングで `embed.min.js` の